



**Hochschule für Technik
und Wirtschaft Berlin**

University of Applied Sciences

Untersuchung von Image Colorization Methoden anhand
Convolutional Neuronal Networks

Abschlussarbeit

zur Erlangung des akademischen Grades

Bachelor of Science (B.Sc.)

an der

Hochschule für Technik und Wirtschaft Berlin
Fachbereich IV: Informatik, Kommunikation und Wirtschaft
Studiengang Angewandte Informatik

1. Prüfer: Prof. Dr. Christin Schmidt
2. Prüfer: M.Sc. Patrick Baumann

Eingereicht von: Adrian Saiz Ferri
Immatrikulationsnummer: s0554249
Eingereicht am: XX.XX.2020

Abstract

Inhaltsverzeichnis

1 Einleitung	1
1.1 Motivation	1
1.2 Zielsetzung	1
1.3 Vorgehensweise und Aufbau der Arbeit	2
2 Grundlagen	3
2.1 Neuronale Netze	3
2.1.1 Feedforward Neural Network	4
2.1.2 Fully-connected Neural Network	4
2.1.3 Aktivierungsfunktionen	6
2.2 Convolutional Neural Networks	9
2.2.1 Loss Functions	12
2.2.2 Optimierungsalgorithmen	13
2.2.3 Backpropagation	15
2.2.4 Transposed Convolution	16
2.2.5 Autoencoder	16
2.3 <i>Lab</i> -Farbraum	17
2.4 Verwandte Arbeiten	18
3 Konzeption	19
3.1 Image Colorization als Multimodales Problem	19
3.2 Farbraum	19
3.3 Binning	20
3.3.1 Umwandlung von Bin zu Farbe	21
3.4 Netzwerkarchitektur	22
3.4.1 U-net	23
3.5 Datensätze	24
3.6 Image Preprocessing und Augmentation	26
3.7 Tools	27

4 Implementierung	28
4.1 Binning	28
4.1.1 Umwandlung von Bin zu Farbe	29
4.2 Datensätze	30
4.3 Netzwerkarchitektur	30
4.3.1 ConvBlock	31
4.3.2 U-Net	31
5 Experimente	33
5.1 Spiel-Datensatz Experimente	33
5.2 CIFAR-100 Subset Experimente	34
5.2.1 Experimente mit MSE Loss und ohne Binning	36
5.3 Landscape Datensatz Experimente	37
6 Evaluation	39
6.1 Evaluationsmetrik	39
6.2 Evaluation des Spiel-Datensatzes	39
6.3 Evaluation des CIFAR-100 Subsets	40
6.4 Evaluation des Landscape Datensatzes	42
7 Fazit	44
7.1 Zusammenfassung	44
7.2 Kritischer Rückblick	44
7.3 Ausblick	45
Abbildungsverzeichnis	I
Source Code Content	III
Glossar	IV
Literaturverzeichnis	V
Onlinereferenzen	VI
Bildreferenzen	VII
Anhang A	VIII
Eigenständigkeitserklärung	IX

Kapitel 1

Einleitung

Das Kapitel Einleitung verschafft einen

1.1 Motivation

Jeder hat sich sicherlich gefragt, vor allem wenn es um Familienbilder geht, wie ein schwarz/weiß Bild in Farbe aussehen würde. Ein schwarz/weiß Bild kann interaktiv von einem Mensch gefärbt werden, sodass Farben möglichst akkurat vergeben werden. Wenn jedoch mehrere Tausend Bilder zu bearbeiten sind, wird das einige Zeit in Anspruch nehmen. Dieses Problem kann mit Deep Learning gelöst werden, indem ein Algorithmus selbstständig und möglichst realistisch, ein schwarz/weiß Bild färbt. Der Prozess der Einfärbung eines Bildes ist ein aktives Forschungsgebiet in Deep Learning. Es gibt bereits Methoden, basierend auf Convolutional Neuronal Networks, die sehr realistische Ergebnisse liefern.

1.2 Zielsetzung

Das Ziel dieser Arbeit ist die bestehenden Methoden zu untersuchen, zu implementieren und zu vergleichen. Der Fokus wird auf Methoden, die das Problem von Image Colorization als ein Multimodales Problem behandeln und implementiert auf Grund dessen, Klassifikationsmethoden.

1.3 Vorgehensweise und Aufbau der Arbeit

Die vorliegende Arbeit lässt sich in fünf Hauptkapitel aufteilen. Zu Beginn wird eine ausführliche Erläuterung der Grundlagen gegeben, um die Methoden und Techniken der Arbeit zu verstehen. Anschließend werden die Konzepte, Techniken und Methoden präsentiert. Um auf die bevorzugte Methode aufzubauen zu können werden einige Datensätze gebraucht, diese werden bei den Konzepten präsentiert. Nachdem auch diese erläutert wurden, wird die Implementierung erklärt. Darauf folgend werden zahlreiche Experimente mit verschiedenen Hyperparametern durchgeführt. Abschließend werden die Experimente evaluiert und mit anderen Methoden verglichen.

Kapitel 2

Grundlagen

Dieses Kapitel verschafft einen Überblick über die benötigten theoretische Grundlagen, um die Methoden dieser Arbeit zu verstehen. Zunächst wird eine Einführung in Neuronale Netzwerke gegeben, anschließend werden einzelne Bestandteile und Varianten von Neuronalen Netzwerken erklärt. Als nächstes wird der “Lab-Farbraum” kurz erläutert. Abschließend wird ein Überblick über verwandte Arbeiten gegeben.

2.1 Neuronale Netze

Künstliche Neuronale Netze sind vom menschlichen Gehirn inspiriert und werden für Künstliche Intelligenz und Maschinelles Lernen angewendet. Genutzt werden sie für überwachtes und unüberwachtes lernen. In der vorliegenden Arbeit werden nur Methoden des überwachten lernens angewendet. Beim überwachten lernen sind die Datensätze gelabelt, sodass der Output des Neuronalen Netzes mit den richtigen Ergebnissen verglichen werden kann.

Neuronale Netze bestehen aus Neuronen, auch “Units” genannt, die schichtenweise in “Layers” (Schichten) angeordnet sind. Beginnend mit der Eingabeschicht (Input Layer) fließen Informationen über eine oder mehrere Zwischenschichten (Hidden Layer) bis hin zur Ausgabeschicht (Output Layer). Dabei ist der Output des einen Neurons der Input des nächsten. [Moe18]

2.1.1 Feedforward Neural Network

Das Ziel von einem Feedforward Neural Network ist die Annäherung an eine Funktion f^* . Ein Feedforward Neural Network definiert eine Abbildung $y = f(x; W)$ wobei x der Input ist und W die lernbaren Parameter sind (auch Gewichte genannt). [GBC16, S. 164-223]

Diese Netzwerkarchitektur trägt den Namen “feedforward” weil der Informationsfluss von der Input Layer, über die Hidden Layers bis zur Output Layer in eine Richtung weitergereicht wird.

Feedforward Neural Networks werden als eine Kette von Funktionen dargestellt. So, kann man die Funktionen $f^{(1)}, f^{(2)}, f^{(3)}$ in Form einer Kette verbinden, um $f(\mathbf{x}) = f^{(3)}(f^{(2)}(f^{(1)}(\mathbf{x})))$ zu bekommen. Diese Kettenstrukturen sind die am häufigsten genutzte Struktur bei Neuronalen Netzwerken. Im genannten Beispiel ist $f^{(1)}$ der erste Layer, $f^{(2)}$ der zweite und $f^{(3)}$ der Output Layer von diesem Netzwerk. Die Länge dieser Kette definiert die Tiefe des Netzwerks. Je tiefer ein Netzwerk ist, desto mehr erlernbare Parameter besitzt es und braucht somit eine erhöhte Rechenleistung, um trainiert zu werden. In der Praxis sind die Netzwerke sehr tief, daher der Begriff Deep Learning.

Während dem Training werden die Gewichte von $f(x)$ verstellt, um $f^*(x)$ zu erhalten. Jedes Trainingsbeispiel x ist mit einem Label $y = f^*(x)$ versehen. Die Trainingsbeispiele geben genau vor, was der Output Layer generieren soll. Der Output Layer soll Werte generieren, die nah an y liegen. Das Verhalten der Hidden Layers wird nicht durch die Trainingsbeispiele festgelegt, sondern der Lernalgorithmus soll selbst definieren, wie diese Layers verwendet werden, um die beste Annäherung von $f^*(x)$ zu erzielen.

2.1.2 Fully-connected Neural Network

Fully-connected Neural Networks sind die am häufigsten vorkommende Art von Neuronalen Netzen. In dieser Netzwerkarchitektur sind alle Neuronen eines Layers mit allen Neuronen des vorherigen und des nächsten Layers verbunden. Neuronen die sich im selben Layer befinden, sind jedoch nicht miteinander verbunden. [Fei17a]

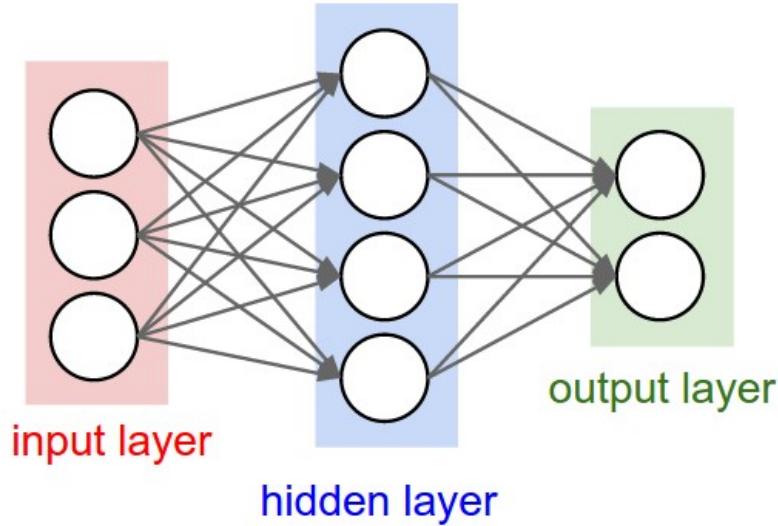


Abbildung 2.1: Fully-connected Neural Network mit 2 Layers (ein Hidden Layer mit 4 Neuronen und ein Output Layer mit 2 Neuronen) [Fei20a]

Einer der wichtigsten Gründe für die Anordnung von Neuronalen Netzen in Layers ist, dass so eine Struktur anhand von Matrix Multiplikationen berechnet werden kann. Die Abbildung 2.1 stellt ein Netzwerk mit 3 Inputs x , eine Hidden Layer mit 4 Neuronen und eine Output Layer mit 2 Neuronen dar. Die Kreise repräsentieren die Neuronen und einen Bias Wert b , die Pfeile stellen die Gewichte w dar.

$$f(x) = w * x + b \quad (2.1)$$

Nach jeden Hidden Layer läuft der Output durch eine Aktivierungsfunktion σ die unter Kapitel 2.1.3 erklärt wird. Dadurch wird die vorherige Formel um σ erweitert:

$$f(x) = \sigma(w * x + b) \quad (2.2)$$

Forward Pass

Der Forward Pass von einem Neuronalen Netz wird anhand von Matrizen Multiplikationen berechnet. Um dies zu veranschaulichen wird es anhand eines Beispiels erklärt.

Ausgehend von einem Netzwerk mit 3 Inputs, einer Hidden Layer mit 2 Neuronen und einem Output Neuron, ergeben sich folgende Beispielwerte:

$$X = \begin{pmatrix} 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix} \quad W = \begin{pmatrix} 10 & 20 \\ -20 & -40 \\ 20 & 0 \\ -40 & 0 \end{pmatrix} \quad W_{out} = \begin{pmatrix} 20 \\ 40 \\ -40 \end{pmatrix} \quad (2.3)$$

X sind die Inputs, W die Gewichte des Hidden Layers und W_{out} die Gewichte des Output Layers. Die erste Spalte aus dem Input X und die ersten Zeilen aus beide Gewichtsmatrizen W und W_{out} sind die Werte für den Bias. Diese Anordnung des Bias Wertes ermöglicht die Berechnung durch eine einzige Matrix Multiplikation. Als Aktivierungsfunktion wird ReLU [NH10] verwendet:

$$f(x) = \begin{cases} 0 & \text{if } x < 0 \\ x & \text{if } x \geq 0 \end{cases} \quad (2.4)$$

Im ersten Schritt durchläuft der Input durch das Hidden Layer $f(X \times W)$:

$$f \left(\begin{pmatrix} 1 & 0 & 1 & 1 \\ 1 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 \end{pmatrix} \times \begin{pmatrix} 10 & 20 \\ -20 & -40 \\ 20 & 0 \\ -40 & 0 \end{pmatrix} \right) = \begin{pmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 0 \end{pmatrix} \quad (2.5)$$

Im zweiten Schritt wird der Output von der vorherigen Multiplikation mit den Gewichten des Output Layers multipliziert:

$$f \left(\begin{pmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 0 \end{pmatrix} \times \begin{pmatrix} 20 \\ 40 \\ -40 \end{pmatrix} \right) = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad (2.6)$$

2.1.3 Aktivierungsfunktionen

Eine Aktivierungsfunktion definiert die Aktivierungsrate von einem Neuron. Es gibt verschiedene Aktivierungsfunktionen:

Sigmoid

Sigmoid ist eine nicht lineare Funktion welche die Werte in einem Wertebereich von $[0, 1]$ bringt. Große negative Werte werden annähernd 0 und große positive Werte werden annähernd 1. Sigmoid hat einige Nachteile, so neigt es dazu den Gradienten verschwinden zu lassen und die Outputs sind nicht Null zentriert. Sigmoid wird definiert als:

$$\sigma(x) = \frac{1}{1 + e^{-x}} \quad (2.7)$$

wobei x ein Input ist.

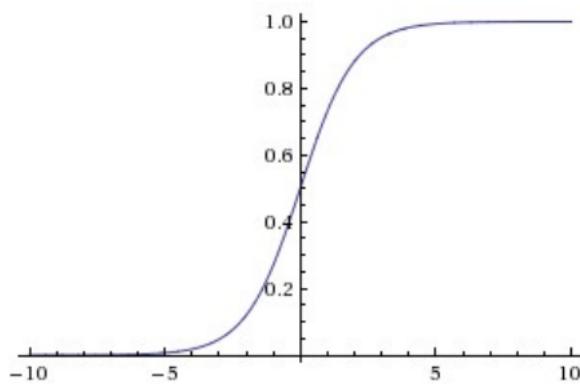


Abbildung 2.2: Sigmoid Aktivierungsfunktion [Fei20b]

Tanh

Die Tanh Aktivierungsfunktion bringt Werte in einen Wertebereich von $[-1, 1]$. Es ist eine skalierte Sigmoid (σ) Funktion, $tanh(x) = 2\sigma(2x) - 1$. Die Nachteile von Tanh ähneln den von Sigmoid, wobei jedoch der Output Null zentriert ist.

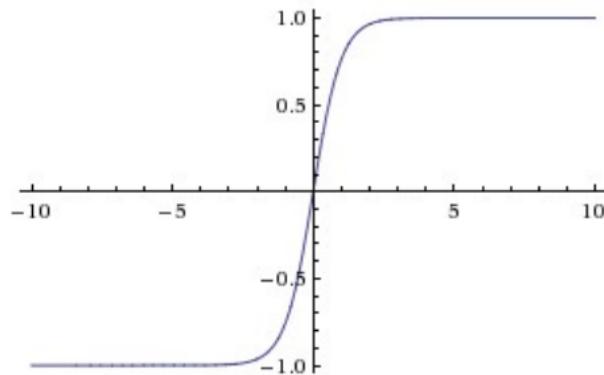


Abbildung 2.3: Tanh Aktivierungsfunktion [Fei20b]

ReLU

Die Rectified Linear Unit konvertiert alle negativen Werte zu 0 und alle positiven Werte behalten ihre Identität. Diese Aktivierungsfunktion wurde für die Netzwerke in dieser Arbeit verwendet da, sie Vorteile gegenüber Sigmoid zeigt. Einer der Vorteile ist, dass die mathematische Auswertung der Funktion unkompliziert ist. Außerdem beschleunigt sie die Konvergenz des Stochastischen Gradientenabstiegsverfahrens im Vergleich zu Sigmoid. ReLU ist definiert als:

$$f(x) = \max(0, x) \quad (2.8)$$

wobei x ein Input ist.

Neuronen die ReLU als Aktivierungsfunktion verwenden können während des Trainings “sterben”. Zum Beispiel, wenn der Gradient in einem Neuron zu groß ist, kann dieser zu einem Update der Gewichte führen, wodurch das Neuron nie wieder aktiviert werden kann. Mit einer korrekten Einstellung der Lernrate kann das vermieden werden. [Fei17a]

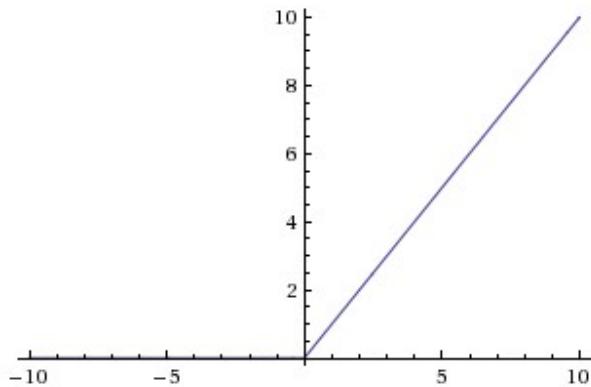


Abbildung 2.4: Rectified Linear Unit (ReLU) [Fei20b]

Leaky ReLU

Leaky ReLU ist eine Variante der ReLU Aktivierungsfunktion, die versucht das Problem der “sterbenden” Neuronen zu minimieren. Anstatt alle negativen Werte zu Null zu konvertieren, werden die Werte mit einer Konstanten multipliziert. Die Funktion wird zu $f(x) = 1(x < 0)(\alpha x) + 1(x \geq 0)(x)$, wobei α eine Konstante mit geringerem Wert ist, zum Beispiel 0.001.

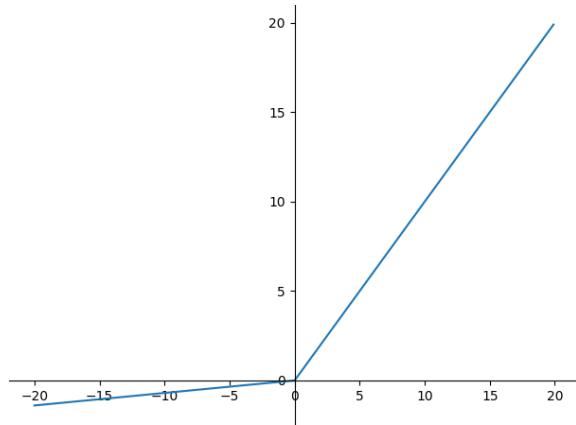


Abbildung 2.5: Leaky ReLU [ccs20]

2.2 Convolutional Neural Networks

Convolutional Neural Networks (CNN) sind eine besondere Form von künstlichen neuronalen Netzwerken, die unter anderen speziell für die Verarbeitung von Bildern vorgesehen

sind [Dip19].

Im Gegensatz zu traditionellen neuronalen Netzwerken, die einen Vektor als Input nehmen, nehmen Convolutional Neural Networks ein 3D Volumen als Input ($W \times H \times C$, hierbei ist W die Breite, H die Höhe und C sind die Farbkanäle).

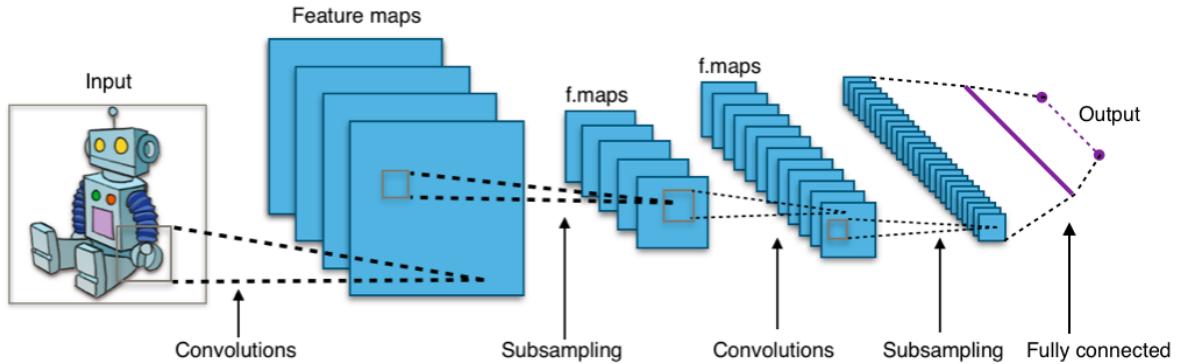


Abbildung 2.6: Typische Struktur von einem Convolutional Neural Network [Com15]

CNNs bestehen in der Regel aus 2 Formen von Layers, die Convolutional Layer und die Pooling Layer.

Die Convolutional Layer besteht aus mehreren hintereinander geschalteten 3 dimensionalen Filtern, auch Kernel genannt ($W \times H \times D$, wobei D die Tiefe der Feature maps darstellt), die während dem Forward pass mit einer festgelegten Schrittweite (Stride), über das Bild geschoben werden. Mit dem sogenannten Padding wird das Verhalten an den Rändern festgelegt. An jeder Stelle wird eine Matrix Multiplikation zwischen den Filter und die aktuelle Position auf dem Bild durchgeführt. Als Output wird eine 2 dimensionale Feature map generiert. Die Größe dieser Feature map ist abhängig von der Größe des Filters, dem Padding und vor allem dem Stride. Ein Stride von 2 bei einer Filter Größe von 2×2 führt beispielsweise pro Filter zu einer Halbierung der Größe der Feature map im Vergleich zum Input Volumen [Bec19]. Ein Stride von 1 bei einem 3×3 Filter mit Padding 1 führt zu einer Feature map mit der gleichen Größe wie der Input Volumen.

Die Filter erkennen in den ersten Ebenen einfache Strukturen wie Linien, Farben oder Kanten. In den nächsten Ebenen lernt das CNN Kombinationen aus diesen Strukturen wie Formen oder Kurven. In den tieferen Layers werden komplexere Strukturen und Objekte identifiziert.

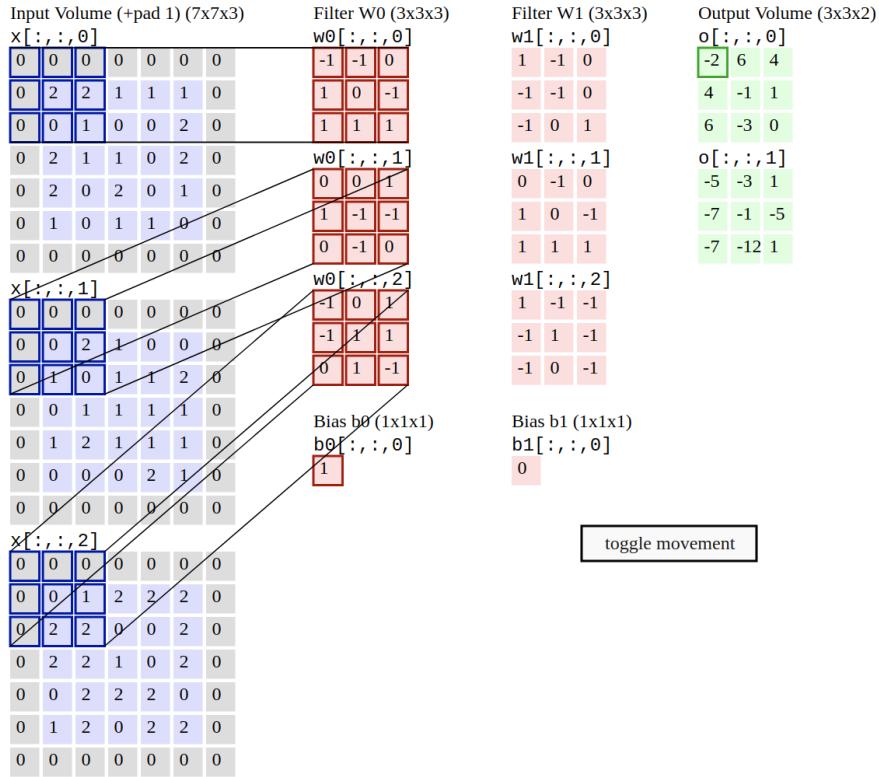


Abbildung 2.7: Beispiel Forward pass von einem Convolutional Layer mit einem $7 \times 7 \times 3$ Input Volumen, zwei $3 \times 3 \times 3$ Filter, Padding 1 und Stride 2. [Fei20c]

Die Pooling Layer dient zur Reduktion der Dimensionen von einem Input Volumen und somit die Parameter von dem Netzwerk. Es gibt verschiedene Pooling Operationen die angewendet werden können, wie zum Beispiel Maximum Pooling, Minimum Pooling, oder Average Pooling. Im Rahmen dieser Arbeit wird Maximum Pooling (oder Max Pooling) verwendet.

Ein Max Pooling Layer aggregiert die Aktivierungsmatrizen von Convolutional Layers, in dem nur die höchste Zahl von einem Filter weitergegeben wird. Zum Beispiel, bei einem 2×2 Filter wird aus 4 Zahlen nur 1 Zahl weitergegeben. Damit wird einer Reduktion der Dimensionen erreicht.

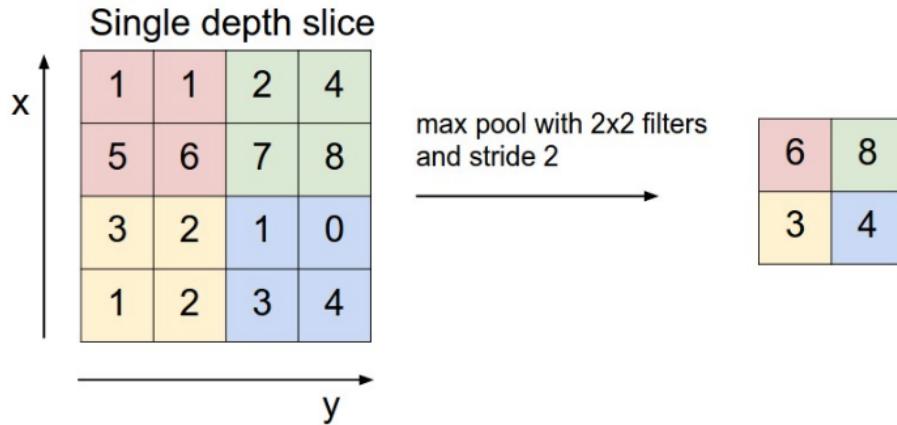


Abbildung 2.8: Max pooling Operation mit 2×2 Filtern und Stride 2 [Fei20c]

2.2.1 Loss Functions

Die Loss Function (Kostenfunktion) dient zur Feststellung der Fehler (Loss) zwischen dem Output von einem Model und die Zielwerte. Das Ziel von Neuronalen Netzen ist es den Loss zu minimieren. Wenn der Loss gleich Null ist, heißt dass $y = \hat{y}$. Es gibt verschiedene Arten von Loss Functions. Im Rahmen dieser Arbeit werden Loss Functions bezogen auf Regressions- und Klassifizierungsprobleme behandelt.

Mean Square Error Loss

Mean Square Error (MSE) Loss misst der mittlere quadratische Fehler und ist definiert als:

$$J = \frac{1}{N} \sum (y - \hat{y})^2 \quad (2.9)$$

wobei, J der Loss ist, N die Anzahl der Klassen, y die Korrekte Klasse (Ground Truth) und \hat{y} die vorhergesagte Klasse ist.

Cross Entropy Loss

Der Cross Entropy Loss wird bei Klassifizierungsprobleme verwendet. Es gibt 2 Arten, Binär und Multiclass Cross Entropy Loss. Bei der Multiclass Cross Entropy Loss wird ein Vektor mit einer Wahrscheinlichkeitsverteilung $x \in [0, 1]$ ausgewertet, wenn die Korrekte

Klasse eine 1 hat ist der Loss 0. Je weniger Wahrscheinlichkeit die Korrekte Klasse besitzt desto höher der Loss sein wird. Der Multiclass Cross Entropy Loss ist definiert als:

$$J = -\frac{1}{N} \left(\sum_{i=0}^N y_i * \log(\hat{y}_i) \right) \quad (2.10)$$

wobei, J der Loss ist, N die Anzahl der Klassen, y die Korrekte Klasse (Ground Truth) und \hat{y} die vorhergesagte Klasse ist.

Weighted Cross Entropy Loss

Bei der Weighted Cross Entropy Loss werden die Klassen gewichtet bevor der Loss berechnet wird. Das ist zum Beispiel nützlich um Klassen mit einer niedrige Wahrscheinlichkeit zu bevorzugen.

2.2.2 Optimierungsalgorithmen

Das Ziel von Optimierungsalgorithmen ist eine Kombination von Gewichte W zu finden, dass die Loss Function minimiert. Es gibt verschiedene relevante Optimierungsalgorithmen. In der vorliegende Arbeit werden Gradient Descent und Adam verwendet.

Gradient Descent

Gradient Descent (Gradientenabstiegsverfahren) ist ein iteratives Verfahren, um bei einer Funktion das Minimum (oder das Maximum) zu finden. Mit Hilfe von partielle Ableitungen kann der Gradient von einer Funktion berechnet werden. Ein Gradient ist, in dem Fall von Neuronale Netze, ein Vektor der zum höchsten Punkt der Loss Function zeigt. Wird der negative Gradient genommen, zeigt dieser zum tiefsten Punkt. Bei jeder Kombination von Gewichte wird der Gradient berechnet und mal eine bestimmte Lernrate α multipliziert, anschließend werden alle Gewichte aktualisiert. Die Lernrate definiert die Größe der Schritte in Richtung Minimum. Die Update Regel für die Gewichte ist definiert als:

$$w_{x+1} = w_x - \alpha * \nabla J(w_x) \quad (2.11)$$

wobei, w_{x+1} die aktualisierte Gewichte sind, w_x die vorherige Gewichte, α die Lernrate und $\nabla J(w_x)$ der Gradient ist. Die Update Regel für den Bias sieht identisch aus.

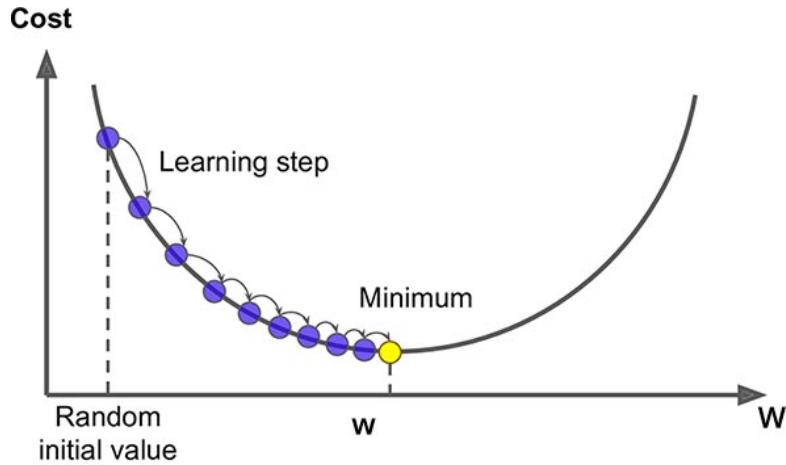


Abbildung 2.9: Gradient descent visualisiert [Bha18]

Es gibt verschiedene Arten von Gradient Descent, Mini-Batch Gradient Descent und Stochastisches Gradient Descent. Bei den normalen Gradient Descent werden die Gradienten im Bezug zu den gesamten Datensatz berechnet und damit das Update durchgeführt. Mini-Batch Gradient Descent berechnet die Gradienten im Bezug zu einem kleinen Teil von dem Datensatz und führt einen Update für alle Parameter durch. Letztendlich, Stochastisches Gradient Descent berechnet den Gradient bezogen auf einem einzigen Element von dem Datensatz und führt einen Update für alle Parameter durch.

Um die Konvergenz Richtung Minimum zu beschleunigen, wurde das Gradient Descent mit Momentum entwickelt. Bei diesem Ansatz wird einen Geschwindigkeitsparameter zu der Update Regel hinzugefügt die alle vorherige Updates akkumuliert. Das ermöglicht die schnellere Konvergenz mit jedem Schritt. Die neue Update regel ist definiert als:

$$\begin{aligned} v_{t+1} &= \rho v_t - \alpha * \nabla J(w_x) \\ w_{x+1} &= w_x + v_{t+1} \end{aligned} \tag{2.12}$$

wobei v_{t+1} der nächste Geschwindigkeitsparameter ist, v_t der aktuelle Geschwindigkeitsparameter und ρ ein Reibungsparameter (typisch 0.9) zu Regulierung ist.

Adam

Adam steht für “Adaptive Moment Estimation Algorithm” und ist ein Optimierungsalgorithmus der eine angepasste Lernrate für die verschiedene Parameter berechnet [KB14]. Adam ist der bevorzugte Optimierungsalgorithmus für die vorliegende Arbeit. Adam kombiniert die Ansätze von AdaGrad [DHS11] und RMSProp. AdaGrad ist eine verbesserte Version von Gradient Descent dass eine angepasste Lernrate für die verschiedene Parameter einführt.

2.2.3 Backpropagation

Neuronale Netze lernen in dem das Loss minimiert wird. Wie in der vorherigen Sektionen erläutert, bestimmt die Loss Function, die Fehlerrate von einem Neuronalem Netz. Dieses Loss kann mit Hilfe von einem Optimierungsalgorithmus reduziert werden. Backpropagation ermöglicht es, einer effizienten Berechnung der Gradienten in einem neuronalen Netzwerk [15]. Mit Hilfe der Kettenregel kann eine komplexe Loss Function in kleinere Unterfunktionen zerlegt werden um lokal die Ableitung zu berechnen. Das ermöglicht eine unkomplizierte Berechnung des Gradienten.

Als Beispiel kann die folgende Sigmoid Funktion in Unterfunktionen zerlegt werden:

$$f(w, x) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2)}} \quad (2.13)$$

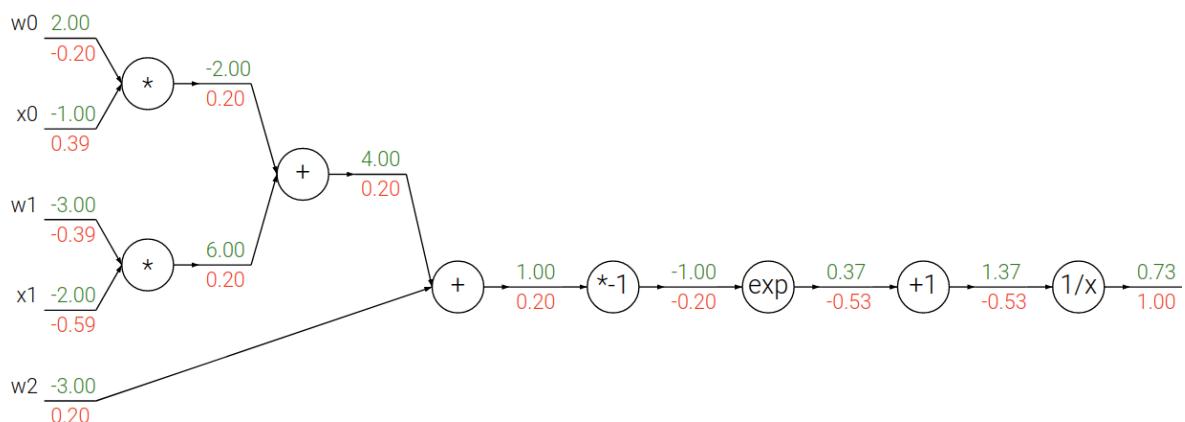


Abbildung 2.10: Backpropagation Beispiel anhand einer 2D Neuron mit der Aktivierungsfunktion Sigmoid [Fei20d]

Bei dem oberen Bild sind $[w_0, w_1, w_2]$ die Gewichte und $[x_0, x_1]$ die Inputs des Neurons. Um es unkompliziert zu halten, kann die obere Funktion als irgendeine Funktion, die Inputs (w, x) entgegennimmt und eine einzelne Zahl als Output hat, visualisiert werden. Die Grüne Zahlen repräsentieren die Ergebnisse aus dem Forward Pass und die Rote Zahlen der zurück propagierte Loss. Jeder Knoten ist fähig ein Output und der lokale Gradient von dem Output im Bezug auf den Input zu berechnen, ohne die komplette Funktion kennen zu müssen [Fei17b].

2.2.4 Transposed Convolution

Im Gegensatz zu einem Pooling Layer, ermöglicht einer Transposed Convolutional Layer die Dimensionen von einem Volumen zu vergrößern. Die funktionsweise einer Transposed Convolution wird anhand von einem Beispiel erklärt.

Ausgehend von einer 2×2 Input Matrix die auf 3×3 vergrößert werden soll, ein 2×2 Filter, Null Padding und Stride 1, ergibt sich den Folgenden Output.

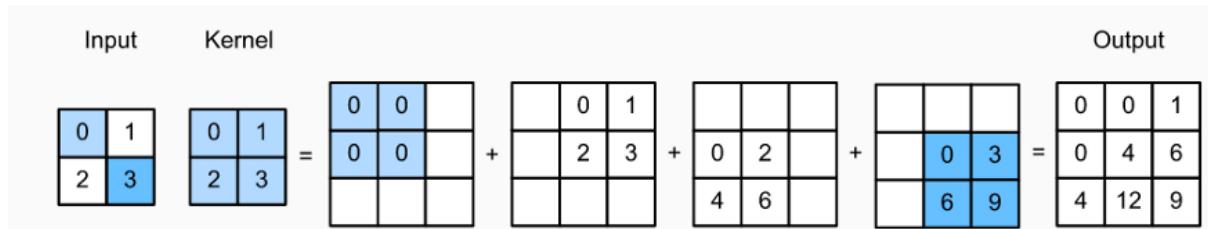


Abbildung 2.11: Die Komplette Transposed Convolution Operation [Zha20]

Jeder Zahl in der Input Matrix wird mit jeder Zahl in den Filter multipliziert. Daraus ergibt sich an jeder Position in der Input Matrix einer 2×2 Matrix. Die überlappende Zahlen auf der Output Matrix werden addiert. Daraus ergibt sich einer 3×3 Output Matrix.

2.2.5 Autoencoder

Ein Autoencoder ist ein neuronales Netz, welches versucht die Eingangsinformationen zu komprimieren und mit den reduzierten Informationen im Ausgang wieder korrekt nachzubilden [Ngu20]. Die Komprimierung und Rekonstruktion der Input läuft in zwei Schritten ab, weshalb das Netz in zwei Teile betrachtet werden kann.

Encoder

Der Encoder reduziert die Dimensionen von einem Input und somit werden die wichtigsten Features in einer reduzierter Dimension komprimiert. In einem neuronalen Netz wird diese Komprimierung durch die Hidden Layers erreicht. Der Encoder ist definiert als:

$$h = f(x) \quad (2.14)$$

wobei x einem Input ist, f der Encoder und h die Kodierten Features von x .

Decoder

Der Decoder ist zuständig für die Rekonstruktion von x anhand h und ist definiert als:

$$\hat{x} = g(h) \quad (2.15)$$

wobei, \hat{x} der rekonstruierte Input ist, g der Decoder und h die Kodierten Features sind.

In der vorliegende Arbeit wird einer Variante von Autoencoders, basierend auf Convolutional Neural Networks, eingesetzt.

2.3 Lab-Farbraum

Der *Lab*-Farbraum (auch CIELAB-Farbraum genannt) ist ein Farbraum definiert bei der Internationale Beleuchtungskommission (CIE) in 1976. Farben werden mit drei Werte beschrieben. “ L ” (Lightness) definiert die Helligkeit. Die Werte liegen zwischen 0 und 100. “ a ” gibt die Farbart und Farbintensität zwischen Grün und Rot und “ b ” gibt die Farbart und Farbintensität zwischen Blau und Gelb. Die Werte für “ a ” und “ b ” liegen zwischen -128 und 127.

In der vorliegende Arbeit wird den *Lab*-Farbraum verwendet, da es unkompliziert ist, den “ L ” Kanal von beide Farbkanäle “ a ” und “ b ” zu trennen. Außerdem bildet den *Lab*-Farbraum das Menschliche Sehvermögen besser als den RGB-Farbraum¹ ab.

¹RGB steht für Red, Green und Blue, die 3 Farbkanäle des Farbraums

2.4 Verwandte Arbeiten

Vor der Erstellung dieser Arbeit wurden Methoden von Image Colorization bereits untersucht. Frühere Methoden waren stark an Menschliches Input gebunden. Der Methode von Levin et al. verwendet Farbstiche auf dem Graustufenbild die Automatisch von einem Algorithmus über das gesamte Bild propagierte werden [LLW04].

Der Fokus dieser Arbeit ist auf voll automatische Image Colorization Methoden gesetzt. Konservative Methoden die Convolutional Neural Networks verwenden, versuchen die Farben von dem Originalen Bild wiederherzustellen in dem die Loss Function die Distanz der vorhergesagte Farbe und die Reale Farbe berechnet. Diese Methoden liefern in der Regel entsättigte und blasse Bilder wie bei [Özb19]. Einer der Gründe für diese Ergebnissen ist dass die Modelle nicht richtig lernen. Zum Beispiel, können Äpfel verschiedene Farben einnehmen, wie Rot oder Grün. Wenn das Netzwerk mit einem MSE Loss trainiert wird und das Datensatz die gleiche oder annähernd gleiche Anzahl an grüne und rote Äpfel hat, wird der Output bei einem Apfel eine Farbe zwischen Rot und Grün sein, was ein entsättigtes Bild erzeugen wird.

Aus diesem Grund betrachtet die vorliegende Arbeit das Problem von Image Colorization als ein Multimodales Problem, da gleiche Objekte verschiedene Farbe einnehmen können. Die vorliegende Arbeit orientiert sich auf die Methoden von Zhang et al. und Billaut et al., die ähnliche Ansätze für Image Colorization vorschlagen. Sie betrachten das Problem als ein Klassifizierungsproblem und trainieren eine CNN mit der Cross Entropy und Weighted Cross Entropy Loss. Der Output des Netzwerks ist eine Wahrscheinlichkeitsverteilung über die mögliche Bins, die im Kapitel 3.3 erläutert werden, für jeden Pixel.

Beide Ansätze verwenden “Color Bins” die es unkompliziert ermöglichen die Farben von jedem Pixel zu klassifizieren. Es wird im nächsten Kapitel weiter auf diese Methode eingegangen.

Kapitel 3

Konzeption

Dieses Kapitel beinhaltet alle Schritte für die Konzeption der angewandte Methode. Außerdem wird der Datensatz und die verwendeten Tools präsentiert.

3.1 Image Colorization als Multimodales Problem

Konventionelle automatische Methoden zielen darauf ab, die Farben für ein generiertes Bild so nah wie möglich an das Originale Bild vorherzusagen. Diese Methoden verwenden ein MSE Loss der Vorhersagen die Weit von den Originalen Farbwerte entfernt liegen, stärker bestraft, als Farbwerte die dichter an den Originalen Farbwerte liegen. Das führt, wie bei 2.4 beschrieben, zu entsättigte Bilder. Die Gründe für diese Ergebnisse ist dass verschiedene Objekte, verschiedene Farben einnehmen können.

Die gewählte Methode dieser Arbeit berücksichtigt die Multimodalität von Image Colorization und behandelt das Problem als Klassifikation.

3.2 Farbraum

Der Standard Farbraum der Bilder für die Methode dieser Arbeit ist der RGB¹-Farbraum. Der RGB-Farbraum hat einige Nachteile die es kompliziert machen mit diesem Farbraum zu arbeiten. Eine der Nachteile ist, dass das Graustufenbild sich schwer von den Farbkanäle trennen lässt. Ein anderes Nachteil ist dass die Farbinformationen in drei Farbkanäle

¹Rot, Grün, Blau

kodiert sind, was die Komplexität eines Models erhöhen würde. Aus diesem Grund werden die Bilder für die Verarbeitung und die Methode in den Lab-Farbraum konvertiert. Für die Darstellung der Ergebnisse werden die Bilder von dem Lab-Farbraum in den RGB-Farbraum konvertiert.

Bei den Lab-Farbraum können ohne Probleme die Farbkanäle “ab” von den Belichtungs-kanal “L” getrennt werden. Der Belichtungskanal “L” enthält das Graustufenbild die in den CNN eingespeist wird.



Abbildung 3.1: Originales Bild in RGB oben links, den Belichtungskanal “L” oben rechts, unten links den Farbkanal “a” und unten rechts den Farbkanal “b”.

3.3 Binning

Binning ist eine Technik, die für die Bildverarbeitung verwendet wird. Binning wird, in dem Kontext von Image Colorization, als Eingruppierung von naheliegenden Farben definiert. Die Farben werden in gleich große Intervalle aufgeteilt. Diese Intervalle bezeichnet man im Englischen als “Bins”. Jedes dieser Intervalle wird durch einen Bin Index repräsentiert, somit reduziert sich die Anzahl der Klassen die vorhergesagt werden können.

Als Beispiel für die Veranschaulichung wird der normalisierte Lab-Farbraum in 36 gleich große Bins unterteilt. Da die Farbinformationen in den “ab” Farbkanäle kodiert sind,

werden nur diese 2 Farbkanäle in Bins klassifiziert. Auf dem Bild 3.2 ist der Farbkanal “a” auf der x-Achse und der “b” Farbkanal auf der y-Achse abgebildet. Die Vierecke repräsentieren die Bins. Die obere Zahl in den Bins symbolisiert die xy Koordinaten auf dem Grid, die untere unterstrichene Zahl symbolisiert den Bin Index. Die xy Koordinaten Grid sind Bedeutsam für die Berechnung der Bins.

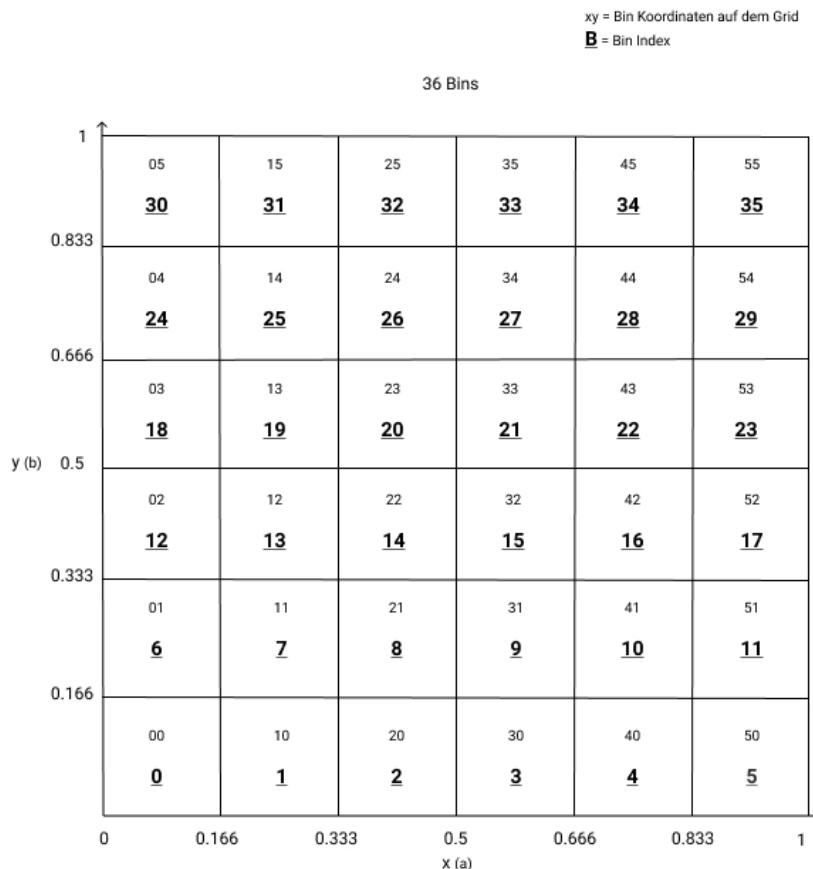


Abbildung 3.2: Grid mit 36 bins. Die x-Achse bildet die Werte von dem Farbkanal “a” und die y-Achse die Werte von den Farbkanal “b” ab.

Für die Methoden dieser Arbeit wurden nur symmetrische Grids verwendet, so ergibt zum Beispiel ein 6×6 Grid 36 Bins und ein 18×18 Grid 324 Bins.

3.3.1 Umwandlung von Bin zu Farbe

Die Umwandlung von Bin zu Farbe muss für die Ergebnisse des Netzwerks ebenfalls vorgegeben sein. Für dieses Problem werden vor dem Training die Farben von jedem Pixel aus

den Trainingsbildern in Bins klassifiziert. Jeder Bin ist durch eine Liste mit zwei Listen, für den jeweiligen Farbkanal, repräsentiert. Jeder Pixelwert wird in der entsprechende Bin Liste hinzugefügt. Anschließend wird der Modus und den Durchschnitt pro Farbkanal der unter jedem Bin klassifizierten Farben ausgerechnet. Zuletzt beinhaltet jeder Bin eine Liste mit zwei Werten, auf dem Nulltem Index der Wert für den Farbkanal “a” und auf dem ersten Index der Wert für den Farbkanal “b”. Es werden zwei separate Dateien erzeugt, eins für den Modus und eins für den Durchschnitt.

Für die Umwandlung von Bin zu Farbe werden die jeweiligen Werten für jeden Farbkanal von einem Bin von der Datei abgeguckt. Es kann zwischen der Durchschnitt und der Modus ausgewählt werden. Der Durchschnitt verhält sich ähnlich wie ein Model trainiert mit dem MSE Loss und der Modus würde Ergebnisse mit einem rötlichen Ton liefern. Als Lösung für dieses Problem schlägt Zhang et al. den “annealed mean” vor [ZIE16]. Den “annealed mean” versucht einen Kompromiss zwischen der Durchschnitt und der Modus zu finden. Dieser Kompromiss ist durch ein Temperatur Parameter (T) reguliert. In der vorliegende Arbeit wird eine von den “annealed mean” inspirierte Methode implementiert. Der Methode wird wie folgendes implementiert:

$$\begin{aligned} D &= K_{mode} - K_{mean} \\ \hat{y}_K &= K_{mode} - (D * T) \end{aligned} \tag{3.1}$$

wobei K ein Farbkanal ist, D die Distanz zwischen Durchschnitt und Modus, T ein Temperaturwert zwischen 0 und 1 ist und \hat{y}_k die Endgültige Farbe für den Farbkanal K ist. Ein Temperaturwert von 1 würde den Durchschnitt ergeben, wiederum würde ein Temperaturwert von 0 den Modus nicht verändern.

3.4 Netzwerkarchitektur

Die Netzwerkarchitektur ist ein wichtiger Faktor dass u.a. die Ergebnisse beeinträchtigt. Wichtig um die Methoden zu vergleichen ist ein leichtes Convolutional Neural Network die wenige Parameter besitzt, schnell zu trainieren ist und gute Ergebnisse liefert.

Das Ziel von dem Netzwerk ist es, ein Graustufenbild als Input zu bekommen und eine Wahrscheinlichkeitsverteilung über alle Bins per Pixel vorherzusagen. Das Output Volumen hat die Dimensionen $W_{Input} \times H_{Input} \times n_bins$, wobei W und H die Breite und

Höhe des Bildes sind und n_bins einer Wahrscheinlichkeitsverteilung über alle Bins pro Pixel ist. Dieser Ansatz ist auch bei Image Segmentation Probleme genutzt, wo ein Bild in das Netzwerk eingespeist wird und ein Segmentation map, mit eine Klasse per Pixel, als Output erzeugt wird. In der Regel wird zu jeder Klasse eine bestimmte Farbe zugeordnet was die Objekte klassifiziert und trennt. In dem Fall von Image Colorization bekommt jeder Pixel in dem Output Volumen eine Wahrscheinlichkeitsverteilung über alle Bins die in einer Farbe umgewandelt wird.

Die Methoden von Zhang et al. [ZIE16] verwenden einen CNN die einen Graustufenbild als Input entgegennimmt und ein Volumen mit eine Wahrscheinlichkeitsverteilung über alle Bins per Pixel generiert. Diese Netzwerkarchitektur besteht aus Blöcke mit jeweils 2 oder 3 Convolutional und ReLU Layers, gefolgt von einem Batch Normalization Layer. Batch Normalization ist eine Regularisierungstechnik die die Werte in einem Hidden Layer normalisiert, bevor sie in den nächsten Layer weitergereicht werden. Das Netzwerk hat keine Pooling Layers, alle Änderungen in der Auflösung werden durch Downsampling oder Upsampling zwischen Blöcke erreicht.

Dieser Netzwerkarchitektur ist sehr schwer für die GPU², was die Batch Größe und Trainingszeit stark beeinflusst.

Aus diesem Grund richtet sich die Netzwerkarchitektur dieser Arbeit nach der Netzwerkarchitektur von Billaut et al. [BRT18]. Sie verwenden eine angepasste Version von einem U-net Convolutional Neural Network [RFB15].

3.4.1 U-net

Ein U-net ist ein Autoencoder mit Skip Connections und Transposed Convolutions als Upsampling Methode der bei Image Segmentation angewendet wird. Im vergleich zu konventionelle Autoencoder, können der Encoder und Decoder nicht getrennt voneinander verwendet werden. Die Skip Connections ermöglichen fein-granuläre Details in dem Output Volumen zu wiederherstellen und helfen mit dem Vanishing Gradient Problem während Backpropagation. Skip Connections konkatenieren bestimmte Layers von dem Encoder mit Layers von dem Decoder, mit der gleichen Dimensionen.

Ein U-net besteht, wie einem Autoencoder, aus einem Encoder und Decoder Teil. Der

²Graphics Processing Unit

Encoder besteht aus sogenannten “ConvBlocks”. ConvBlocks bestehen aus 2 Convolutional Layers gefolgt von Batch Normalization und ReLU. Die ConvBlocks werden gefolgt von einem Pooling Layer die die Dimensionen von dem Volumen verringern. Der Decoder besteht aus ConvBlocks gefolgt von Transposed Convolutions die die Dimensionen von dem Volumen wieder vergrößern. Das letzte Layer ist eine 1×1 Convolutional Layer die das Output Volumen generiert. Skip Connections konkatenieren ConvBlocks aus dem Encoder mit Transposed Convolutions aus dem Decoder mit der gleichen Dimensionen.

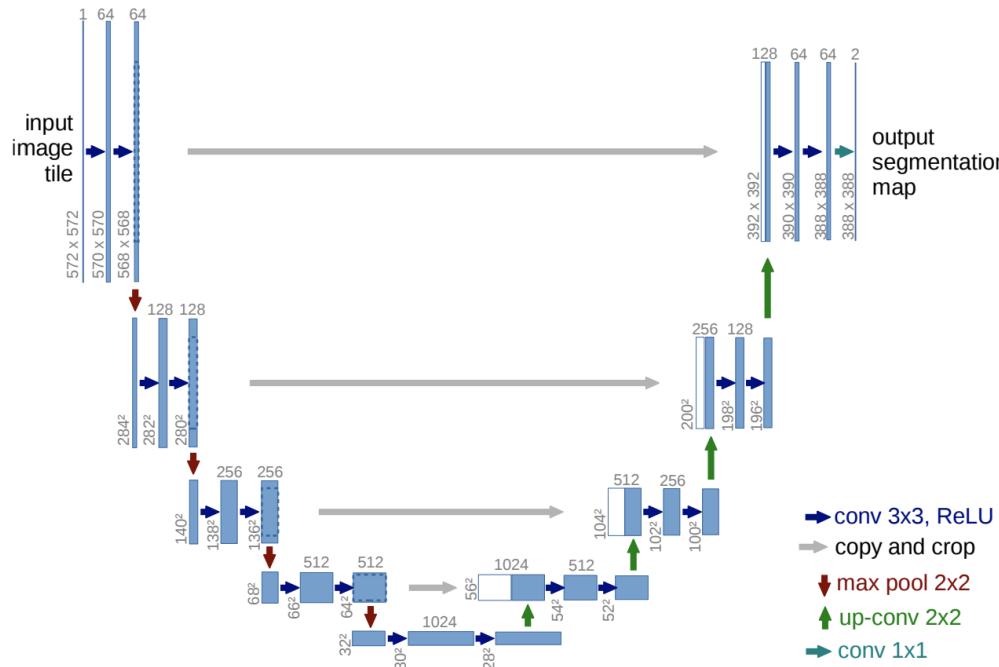


Abbildung 3.3: U-net Architektur (Beispiel für 32×32 Pixels in der niedrigste Auflösung). Jeder blaue Box entspricht ein multi-Kanal Feature Map. Die Tiefe der Feature Maps ist gekennzeichnet durch die Zahl über die Box. Die Breite und Höhe ist durch die Zahl unten links erkennbar. Die weiße Boxen repräsentieren die kopierte Feature Maps. Die Pfeile bestimmen die verschiedene Operationen. [RFB15]

3.5 Datensätze

Um das Netzwerk zu trainieren werden bedeutsame Bilder gebraucht. Ein Vorteil von Image Colorization ist, dass jedes Bild für das Trainieren verwendet werden kann, da nur die Graustufen Version davon gebraucht wird.

Um die Methode zu prüfen werden 3 Datensätze benutzt, die verschiedene Auflösungen und Themen beinhalten.

Als erstes wird ein Spiel-Datensatz von 32×32 Bilder generiert. Dieser setzt sich aus 3 geometrischen Objekten und 3 Farben pro Objekt zusammen. Die geometrischen Objekte sind ein Rechteck, ein Kreis und ein Dreieck pro Bild, die jeweils in eine der 3 Farben eingefärbt sind. Die Bilder haben einen einheitlichen schwarzen Hintergrund.

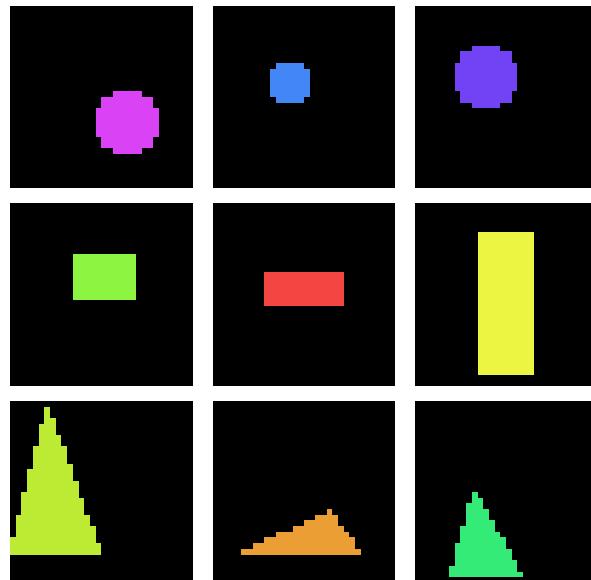


Abbildung 3.4: Beispiel von Trainingsbildern mit einer der möglichen Farbe pro Klasse

Der Datensatz besteht aus 2664 Bilder für das Training und 324 Bilder für das Testen. Dieser Datensatz dient als Beweis für die Methode und hilft bei der Entwicklung und Optimierung des Netzwerks.

Als zweites werden 12 Klassen des CIFAR-100³ Datensatzes verwendet. CIFAR-100 ist ein öffentlich verfügbares Datensatz der von Krizhevsky et al. erstellt wurde. Der Datensatz setzt sich aus 100 Klassen mit jeweils 600 Bildern pro Klasse, außerdem sind die 100 Klassen in 20 Superklassen gruppiert. Der Datensatz wird in 50000 Bilder für das Training und 10000 Bilder für das Testen aufgeteilt. Einige Beispiele für Klassen sind z.B. *apples*, *palm* oder *bee*. Die Bildern haben ebenfalls einer Auflösung von 32×32 .

³CIFAR-100: <https://www.cs.toronto.edu/~kriz/cifar.html>

Da ein Model von Null auf zu trainieren, die jedes Objekt auf dem CIFAR-100 Datensatz richtig erkennt und einfärbt, sehr aufwendig wäre, werden nur bestimmte Klassen für das Training verwendet. Diese Klassen sind: *apples*, *sunflower*, *rose*, *cloud*, *maple_tree*, *oak_tree*, *pine_tree*, *willow_tree*, *palm_tree*, *mountain*, *forest* und *sea*. Alle Klassen haben Gemeinsamkeiten, was das Erlernen von Merkmalen erleichtert im Vergleich zu einem sehr allgemeinen Datensatz.

Abschließend wird ein komplexeres und hochauflösendes Datensatz verwendet, dass Naturbezogene Bilder enthält. Ziel damit ist, ein Netzwerk zu trainieren das Bilder aus Natur einfärben kann. Dieser besteht aus 3 Datensätzen aus Kaggle⁴ und GitHub⁵. Das erste ist das “Landscape Pictures”⁶ Datensatz von Arnaud Rougetet, von diesem Datensatz werden alle Bilder verwendet. Das zweite Datensatz ist das “Landscape Classification”⁷ von Huseyib Gulyev, hiervon werden nur die Klassen *forest*, *glacier*, *mountain* und *sea* verwendet. Das letzte Datensatz ist das “Landscapes dataset”⁸ von ml5js auf GitHub. Von diesem Datensatz wurden die Klassen *field*, *forest*, *lake*, *mountain* und *road* verwendet. Außerdem werden alle Bilder entfernt die nicht eine Öffentliche Lizenz haben.

Das komplette Datensatz besteht aus 8 Klassen und hat insgesamt 12479 Bilder, 10120 für das Training und 2359 für das Testen. Die 8 Klassen sind: *field*, *forest*, *glacier*, *lake*, *mountain*, *road*, *sea* und “ohne Kategorie”. Die Klasse “ohne Kategorie” beinhaltet die Bilder aus dem “Landscape Pictures” Datensatz. Die Klassen sind für das Training und die Methode nicht relevant, da jedes Pixel in Bins klassifiziert wird. Das finale Datensatz wird “Landscape Datensatz” für der Rest der Arbeit benannt.

3.6 Image Preprocessing und Augmentation

Für das optimale Training und Ergebnisse werden die Bilder vorverarbeitet. Außerdem werden Techniken von Image Augmentation angewendet. Das Spiel-Datensatz und die 12 Klassen von CIFAR-100 werden für das Training mit einer Wahrscheinlichkeit von 50% horizontal gespiegelt.

Da das Landscape Datensatz, Bilder mit verschiedene Auflösungen beinhaltet, werden alle Bilder auf 128×128 angepasst. Das reduziert die Trainingszeit und die Komplexität

⁴Kaggle: <https://www.kaggle.com/>

⁵Github: <https://github.com/>

⁶<https://www.kaggle.com/arnaud58/landscape-pictures>

⁷<https://www.kaggle.com/huseynguliyev/landscape-classification?>

⁸<https://github.com/ml5js/ml5-data-and-models/tree/master/datasets/images/landscapes>

von dem Datensatz. Für das Training werden pro Bild, 4 zusätzliche augmentierte Bilder generiert. Erstens werden die Bilder zufälligerweise um ± 30 Grad rotiert, zweitens wird die Größe der Bilder zwischen 0 und 30% geändert, drittens werden die Bilder Horizontal gespiegelt und letztens werden die Bilder Vertikal gespiegelt. Nach der Image Augmentation besteht der Trainings Datensatz aus 50600 Bildern. Für die Evaluation werden die Test Bilder nur auf 128×128 angepasst.

3.7 Tools

Um die Methode zu realisieren werden einige Tools angewendet. Für die Implementierung wird das Framework PyTorch⁹ angewendet. PyTorch ist ein Open-Source Framework basierend auf Python für Machine Learning und Deep Learning. Es wurde von das Facebook AI Research Team entwickelt und erschien im Jahr 2016. Zum Zeitpunkt der Verfassung dieser Arbeit ist die Version 1.6.0 die aktuellste. Für die Farbraum Konvertierung wird das “scikit-image” Bibliothek eingesetzt. Für die Image Augmentation wird die Bibliothek “imgaug” angewendet. Des weiteren werden Hilfsbibliotheken wie “numpy” und “matplotlib” angewendet.

Das Trainieren von den Modellen wird, wegen den hohen Rechenaufwands, auf zwei verschiedene Plattformen durchgeführt. Die Modelle mit den 32×32 Bildern werden auf Google Colab¹⁰ trainiert. Google Colab ist eine Plattform von Google, die es ermöglicht, Experimente im Browser mit einer Hochleistungsgrafikkarte (Nvidia Tesla P100) kostenlos umzusetzen. Für das Modell mit den 128×128 Bildern wird das Curious Containers (CC) Framework¹¹ benutzt. Curious Containers ermöglicht eine gleichzeitige Durchführung von verschiedenen Experimenten in einem Cluster von Hochleistungsrechnern.

⁹<https://pytorch.org/>

¹⁰<https://colab.research.google.com/>

¹¹<https://www.curious-containers.cc/>

Kapitel 4

Implementierung

In diesem Kapitel wird die Implementierung der Methode näher erläutert. Bei der Implementierung werden alle Konzepte aus dem Kapitel Konzeption angewendet.

4.1 Binning

Das Binning ist eine wichtige Komponente der Methode, die auf normalisierte Lab-Bilder mit Hilfe der “numpy” Bibliothek implementiert wurde. Als erstes wird anhand der Anzahl von Bins (n_bins) die Breite (W) und Höhe (H) des Grids, das auf der Abbildung 3.2 zu sehen ist, mit Hilfe der Wurzel berechnet. Es wird angenommen dass $W = H$. Nachdem die Breite des Grids berechnet wurde, wird der Intervall von $[0, 1]$ in W gleich große Intervalle aufgeteilt. Als nächstes wird mit Hilfe der *digitize* Funktion, der Intervall Index der jeweiligen a, b Farbkanal Wert von jedem Pixel kalkuliert. Abschließend werden beide Indices zu einem Bin Index auf dem Grid umgewandelt. Der Output ist ein kodiertes Bild mit einem Bin Index per Pixel.

```

1      # a, b sind die Koordinaten der Farbkanäle auf dem Grid
2      def calculate_bin(a, b, width):
3          return (width * b) + a
4
5      def encode_bins(ab_image, n_bins):
6          W = np.sqrt(n_bins).astype(int)
7
8          # Intervall in gleich große Intervalle aufteilen
9          interval = np.linspace(0, 1, W+1)
10
11         # Indices für jeweils a, b Kanäle berechnen
12         indices = np.digitize(ab_image, interval) - 1
13
14         # Bin Index berechnen
15         bins = np.vectorize(calculate_bin)(indices[:, :, 0], indices[:, :, 1], W)
16
17     return bins

```

Code snippet 4.1: Binning eines normalisierten Lab Bildes

4.1.1 Umwandlung von Bin zu Farbe

Für die Umwandlung werden vor dem Training alle Farben von den Trainingsbilder in Bins klassifiziert. Es wird ein Python Dictionary mit Bin Indices als Key und einem 2-Dimensionalen Array mit einem Array pro Farbkanal als Value erzeugt.

```
1      bin_colors = {i: [[], []] for i in range(n_bins)}
```

Code snippet 4.2: Leeres Dictionary Erzeugung für n_bins

Anschließend werden die Farben von jedem Farbkanal in den jeweiligen Bin Array zugeordnet. Als letztes wird den Durchschnitt pro Bin Index und Farbkanal berechnet. Der Dictionary beinhaltet abschließend ein Array mit 2 einzelne Werte für den jeweiligen Farbkanal pro Bin Index. Somit kann unkompliziert ein Bin in eine Farbe umgewandelt werden.

```

1     a_color = bin_colors[bin_index][0]
2     b_color = bin_colors[bin_index][1]

```

Code snippet 4.3: Bin zu Farbe Umwandlung

Der gleiche Vorgang wird für den Modus angewendet. Um einen Kompromiss zwischen Durchschnitt und Modus zu finden, werden den Durchschnitt und der Modus mit einem Temperatur Wert interpoliert.

```

1     a_distance = a_mode - a_mean
2     b_distance = b_mode - b_mean
3
4     a = a_mode - (a_distance * T)
5     b = b_mode - (b_distance * T)

```

Code snippet 4.4: Bin zu Farbe Berechnung mit einem Temperaturwert

4.2 Datensätze

Die Datensätze werden mit Hilfe der “torchvision” Bibliothek von PyTorch importiert und transformiert. Für das Importieren wurde eine “ImageFolder” implementiert, der die Bilder importiert, transformiert, normalisiert und die einzelne Pixeln in Bins klassifiziert. Der Output von den “ImageFolder” sind das Graustufenbild, das Bild mit den “ab” Farbkanäle und das in Bins kodierte Bild.

Mit Hilfe eines “DataLoaders” werden die Datensätze in Batches aufgeteilt und gemischt.

4.3 Netzwerkarchitektur

Für dieser Arbeit wurden 2 U-Nets mit verschiedene Größen verwendet. Ein U-Net für 32×32 Input Bilder und ein U-Net für 128×128 Input Bilder. Außerdem wurde das U-Net für 32×32 Bilder angepasst damit es mit ein MSE Loss verwendet werden kann. Bei der Anpassung wurde der Output Volumen zu $W_{Input} \times H_{Input} \times 2$ geändert, wobei das Netzwerk direkt die Werte für die “ab” Farbkanäle vorhersagt. Bei der Verwendung von einem MSE Loss wird Binning nicht verwendet.

4.3.1 ConvBlock

Das Kernstück eines U-Nets ist der sogenannte ConvBlock. Ein ConvBlock beinhaltet zwei hintereinander geschaltete Blöcke, die wiederrum aus einer Convolutional Layer mit 3×3 Filtern und Stride 1, gefolgt von ReLU und Batch Normalization bestehen. Die Convolutional Layers verwenden Padding um die Dimensionen von dem Input nicht zu verändern. Die Layers wurden mit den PyTorch Klassen *Conv2d*, *BatchNorm2d* und die Funktion *relu* implementiert. Das ConvBlock wird mit einer Klasse implementiert die wiederrum von der Oberklasse *torch.nn.Module* erbt.

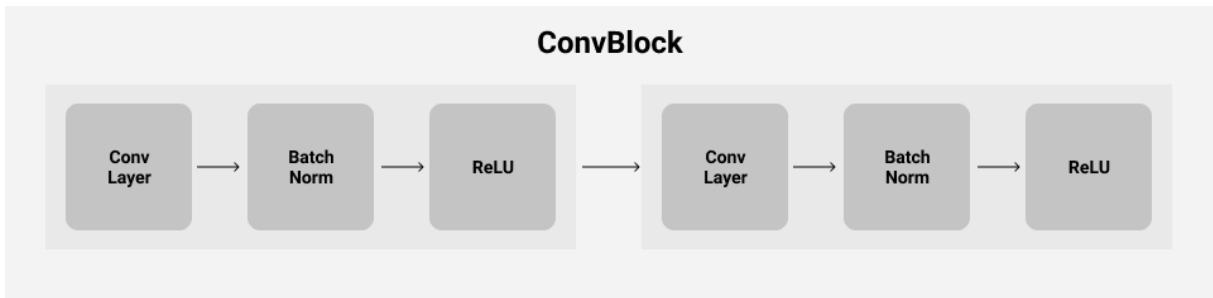
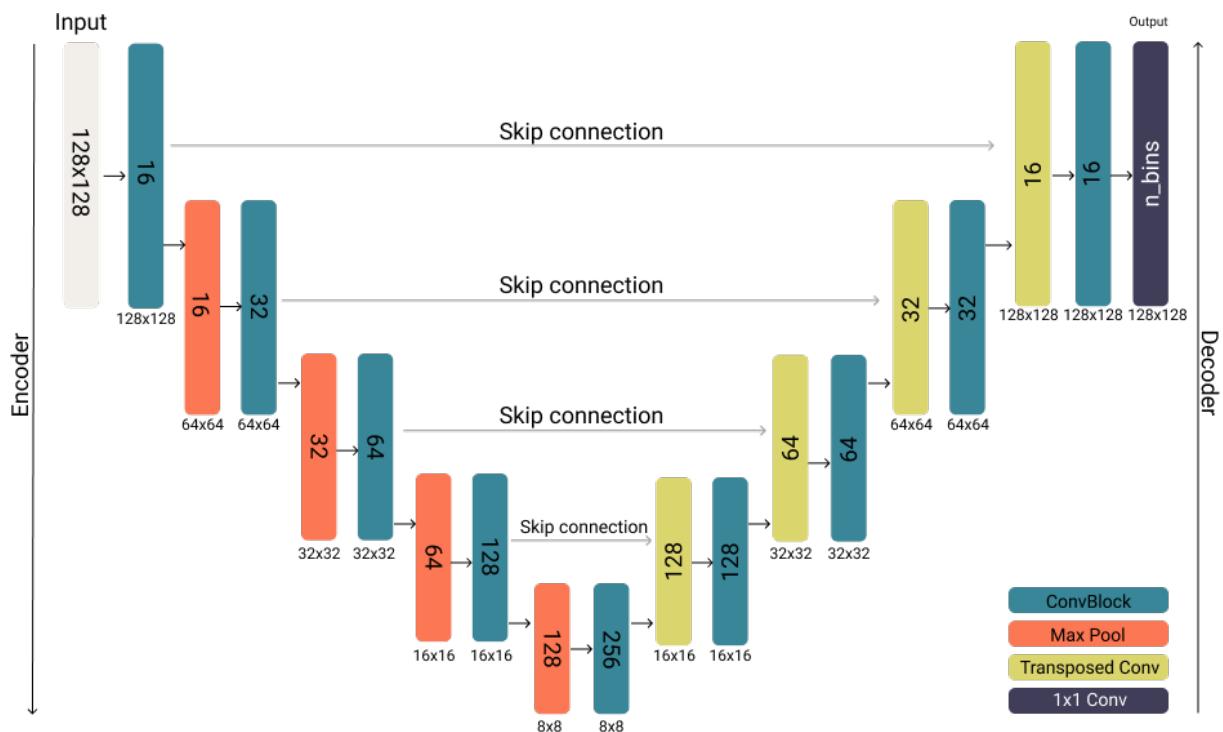


Abbildung 4.1: ConvBlock

4.3.2 U-Net

Das U-Net wird mit den Spezifikationen aus 3.4.1 implementiert. Dies geschieht mit einer Klasse, die von der Oberklasse *torch.nn.Module* erbt. Das U-Net verwendet neben den ConvBlocks, Max Pooling Layers mit einem 2×2 Filter und Stride 2, um die Dimensionen in den Encoder zu halbieren. Die kleinste Größe der Feature Maps bei dem Encoder ist 8×8 . Der Decoder verwendet ebenfalls neben den ConvBlocks, Transposed Convolutions mit 3×3 Filtern, Stride 2 und Padding 1, die die Größe der Feature Maps verdoppeln. Der letzte Layer ist ein Convolutional Layer mit 1×1 Filter, Stride 1 und Padding 0, der die Wahrscheinlichkeitsverteilung pro Pixel generiert. Alle Transposed Convolutions werden mit den Outputs der ConvBlocks mit den gleichen Dimensionen aus dem Encoder konkateniert. Es werden zwei verschieden große U-Nets implementiert, eins für 32×32 Bilder und eins für 128×128 Bilder.

Die Max Pooling Layers wurden mit der *MaxPool2d* Klasse und die Transposed Convolutions mit der *ConvTranspose2d* implementiert.

Abbildung 4.2: U-Net Architektur für 128×128 Input Bilder

Kapitel 5

Experimente

In diesem Kapitel werden Experimente mit den drei Datensätzen durchgeführt. Ebenfalls werden verschiedene Hyperparameter getestet.

5.1 Spiel-Datensatz Experimente

Als erstes wird die Methode auf dem Spiel-Datensatz angewendet. Hiermit soll geprüft werden ob die Methode die erwartete Ergebnisse liefert. Das U-Net wird für 100 Epochen mit Adam, einer Lernrate von 0.001 und die Cross Entropy Loss Function trainiert. Dieser Einstellung erwies die besten Ergebnisse. Außerdem wurde ein Experiment mit 36 und ein mit 324 Bins durchgeführt, was kein Einfluss auf die Ergebnisse vorwies. Es kann davon ausgegangen werden, dass bei der niedrige Anzahl an möglichen Farben, ein Unterschied bei 36 und 324 Bins nicht zu erkennen ist. Die unteren Ergebnissen wurden mit 324 Bins erstellt.

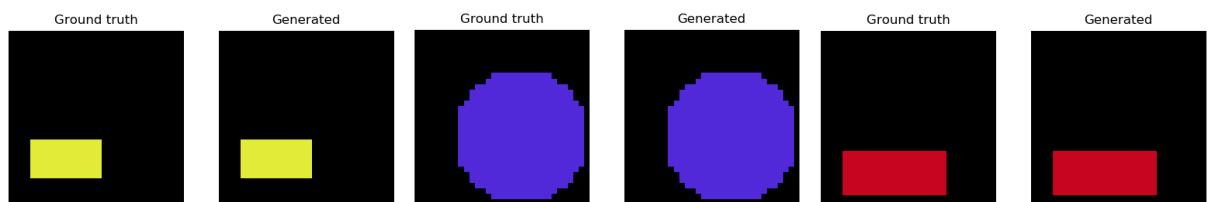


Abbildung 5.1: Beispiele von sehr gute Ergebnisse aus dem Spiel-Datensatz

Bei den oberen Ergebnisse wurden alle Pixeln richtig klassifiziert, was bei der Größe des Datensatzes oft zu overfitting deutet. Die unteren Ergebnissen zeigen dass das Model generalisiert und nicht overfited hat.

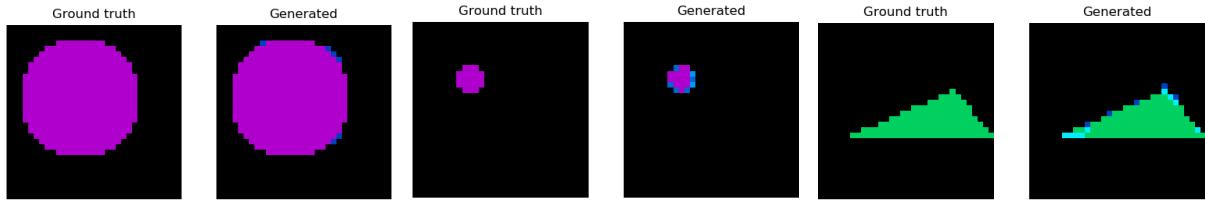


Abbildung 5.2: Beispiele von generalisierte Ergebnisse

Das Model zeigte bei einige Ergebnisse, Schwierigkeiten die Pixeln am Rand der geometrische Formen, richtig zu klassifizieren. Dies tritt speziell auf die Kreise und Dreiecke wo die Ränder nicht aus glatte Linien bestehen. Des weiteren wurden die Farben mittels den Durchschnitt für jeden möglichen Bin über alle Farben von jeden Trainingsbild rekonstruiert. Ein Unterschied zwischen der Modus und der Durchschnitt könnte nicht erkannt werden, da beide Werte gleich waren.

Die Ergebnisse bestätigen dass das Binning und die Methode funktionieren. Anschließend wurden Experimente auf komplexere Bilder von dem Subset von CIFAR-100 durchgeführt.

5.2 CIFAR-100 Subset Experimente

Das Model wurde auf 12 Klassen von CIFAR-100 über 100 Epochen mit Adam, eine Lernrate von 0.001 und die Cross Entropy Loss Function trainiert. Diese Einstellungen ergab sich als die beste Kombination von Hyperparameter, jedoch wurde das Training bei unter 50 Epochen unterbrochen um overfitting zu verhindern.

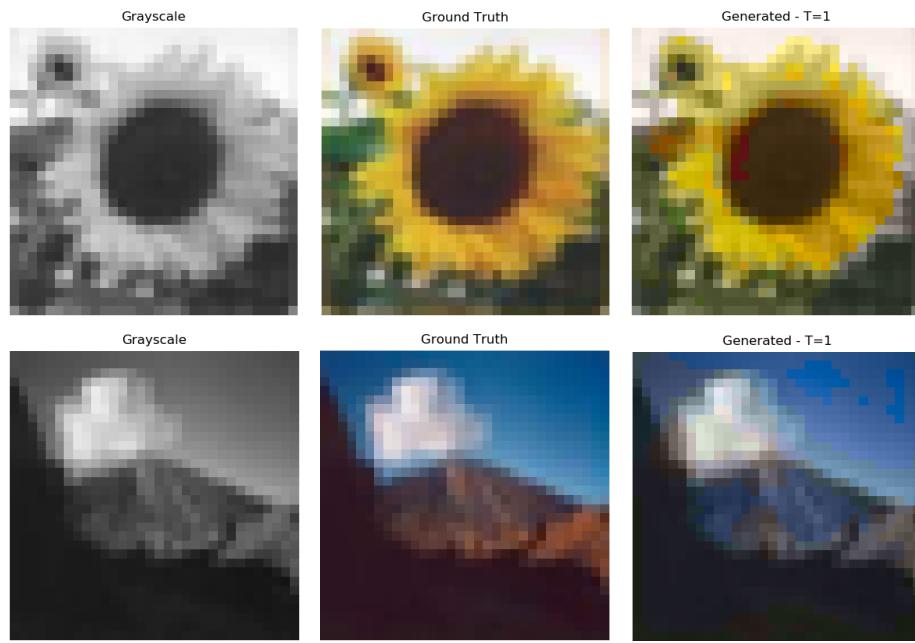


Abbildung 5.3: Beispiele von gute Ergebnisse aus dem Subset von CIFAR-100 mit 324 Bins. Die erste Spalte beinhaltet das Graustufenbild, die zweite Spalte beinhaltet das Originale Bild und die letzte Spalte stellt das generierte Bild dar. Das generierte Bild wurde mit einer Temperatur von 1 erzeugt, was bedeutet dass die rekonstruierte Farben den Durchschnitt aus jedem Bin repräsentieren.

Die Experimente mit diesem Datensatz haben gezeigt dass die Anzahl der Bins bei der Auswahl an möglichen Farben die Ergebnisse beeinträchtigen. Eine Erhöhung an Trainingszeit zwischen 36 und 324 Bins war nicht zu erkennen.

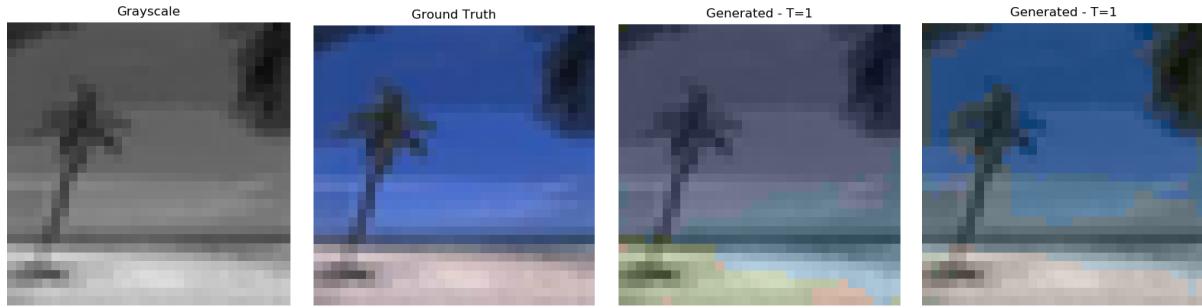


Abbildung 5.4: Einfluss von Anzahl der Bins auf die Ergebnisse. Das zweite Bild ist das originale, das dritte Bild wurde mit 36 Bins und ein Temperaturwert von 1 generiert und das vierte nur mit 324 Bins und ebenfalls mit einem Temperaturwert von 1.

Um das Overfitting zu verhindern wurden Zahlreiche Experimente mit verschiedenen Optimierer, Aktivierungsfunktionen und Lernraten durchgeführt. Eine Ersetzung von ReLU durch Tanh zeigte ein stabileres Trainingsverhalten aber eine Verschlechterung der Validation Loss. Leaky ReLU zeigte ein ähnliches Verhalten wie ReLU aber keine Verbesserung. Die Verwendung von RMSprop anstatt Adam zeigte eine langsamere Konvergenz Richtung Minimum. Abschließend wurden die Anzahl der Filter in den Convolutional Layers halbiert was eine positive Wirkung auf das Training zeigte.

5.2.1 Experimente mit MSE Loss und ohne Binning

Um die Performance von Klassifikation gegenüber Regression zu messen, wurde ein Model mit der MSE Loss Function trainiert. Dieses Model wurde ebenfalls mit den gleichen Parameter wie das Klassifikationsmodel trainiert und hat beeindruckende Ergebnisse erreicht. Einige Ergebnisse zeigten Blasse stellen im Vergleich zu das Klassifikationsmodel, der leuchtende Farben an den gleichen Stellen gezeigt hat.

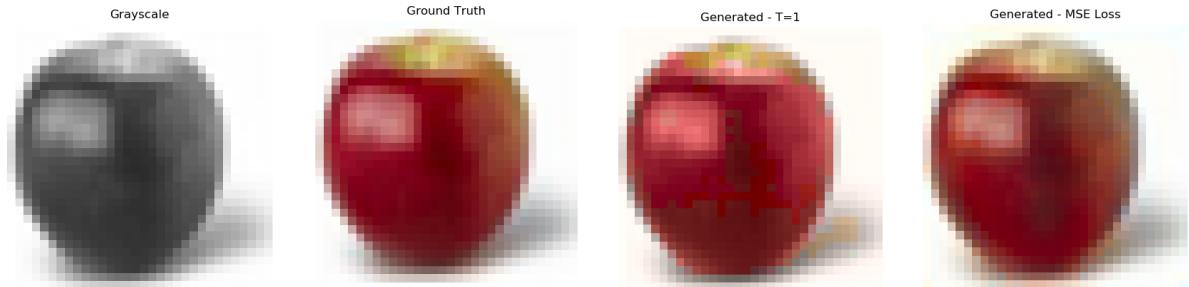


Abbildung 5.5: Vergleich von Klassifikation mit Binning gegenüber Regression. Das zweite Bild wurde mit 324 Bins und der Cross Entropy Loss generiert. Das dritte Bild wurde ohne Binning und mit einem MSE Loss generiert.

5.3 Landscape Datensatz Experimente

Dieser Datensatz wurde anhand der Hyperparameter Optimierung von den CIFAR-100 Subset trainiert. Es wurde das größere Model für 128×128 Input Bilder angewendet. Das Model wurde ebenfalls für 36 und 324 Bins, mit dem Adam Optimizer, eine Lernrate von 0.001 und die Cross Entropy Loss Function für 60 Epochen trainiert. Das Model mit den besten Validation Loss wurde gespeichert um die Ergebnisse zu evaluieren. Außerdem wurden den Einfluss der Temperaturwert und der Anzahl der Bins auf die Ergebnisse gemessen.

Das Model tendierte ebenfalls bei diesem Datensatz zum Overfitting. Um das zu verhindern wurden die gleiche Techniken wie bei CIFAR-100 angewendet, was keine bessere Ergebnisse geliefert hat. Eine Halbierung der Anzahl der Filter bei den Convolutional Layers erwiesen eine Verschlechterung des Validation Loss und half nicht bei Overfitting. Eine Änderung der Optimierer zu RMSprop und die Ersetzung von ReLU durch Tanh zeigten einen stabileren Training aber keine Verbesserung der Validation Loss. Das Endgültige Model wurde trainiert bis der Validation Loss wieder stieg.



Abbildung 5.6: Ergebnisse mit 324 Bins. Die erste Spalte zeigt das Originale Bild, die zweite zeigt das generierte Bild mit einer Temperatur von 0, die dritte Spalte zeigt das generierte Bild mit einer Temperatur von 0.8 und die vierte Spalte zeigt das generierte Bild mit einer Temperatur von 1

Nach der Auswertung der Experimente würden 324 Bins und ein Temperaturwert von 0.8 bis 1 bevorzugt um die bestmöglichen Ergebnissen zu bekommen.

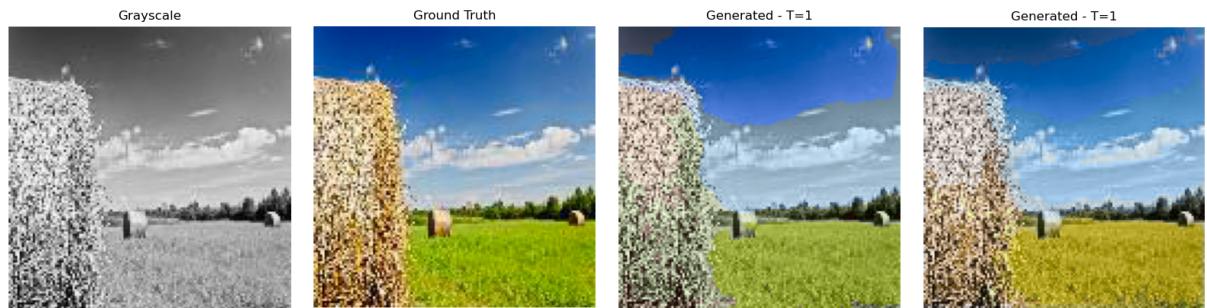


Abbildung 5.7: Ergebnisse mit 36 und 324 Bins. Die erste Spalte zeigt das Graustufenbild, die zweite zeigt das originale Bild, die dritte Spalte zeigt das mit 36 Bins generierte Bild mit einer Temperatur von 1 und die vierte Spalte zeigt das mit 324 Bins generierte Bild mit einer Temperatur von 1

Kapitel 6

Evaluation

Im Kapitel Evaluation werden die im Kapitel 5 vorgestellten Experimenten evaluiert. Außerdem wird die gewählte Methode ausgewertet und mit anderen Methoden verglichen.

6.1 Evaluationsmetrik

Für das Problem von Image colorization existiert keine relevante Evaluationsmetrik die die Farben von den Objekten auf einem Bild auswerten kann. Da während des Training angewendete Cross Entropy Loss ist nicht relevant für die Auswertung der Ergebnisse aus dem Test Datensatz. Aus diesem Grund wurde die Evaluation der Ergebnisse durch eine Menschliche Auswertung wie bei [ZIE16] und [BRT18] durchgeführt.

6.2 Evaluation des Spiel-Datensatzes

Mit dem Spiel-Datensatz wurde die Funktionsweise der Methode bestätigt. Die von Bilalaut et al. vorgeschlagene Netzwerkarchitektur für Image colorization hat beeindruckende Ergebnissen mit wenigen Epochen erreicht.

Die gewählte Methode für das Binning funktionierte und hat ermöglicht die Originale Farben wiederherzustellen. Die Anzahl an Bins war für diesen Datensatz nicht relevant da es nur 9 gleich möglichen Farben gab.

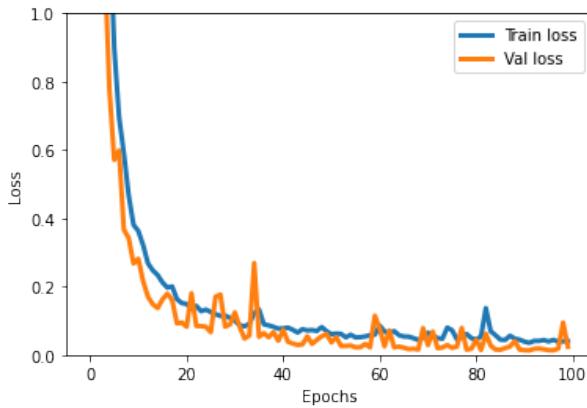


Abbildung 6.1: Training und Validation Loss Verlauf von dem Spiel-Datensatz

6.3 Evaluation des CIFAR-100 Subsets

Die Ergebnissen aus dem CIFAR-100 Subset zeigten dass das Model in wenige Epochen viele Merkmale lernen konnte. Ein wichtiger Faktor zu erwähnen ist dass die Gewichte des Netzwerks zufällig initialisiert wurden und nicht vortrainiert waren.

Auf diesem Datensatz wurde die Auswirkung der Bin Anzahl gemessen. Die Auswahl von 36 Bins zeigten im Vergleich zu 324 eine Verschlechterung der Farben in der Vorhersage. Dies ist darauf zurückzuführen dass das Model nur 36 mögliche Farben zu Verfügung hat. Eine Erhöhung der Bins auf 324, ermöglichte das Model eine Auswahl an mehr Farben zu treffen. Den Ansatz von [BRT18] verwendet nur 32 Bins und erzielt ähnliche Ergebnisse wie die Methode dieser Arbeit mit 324 Bins. Dies wurde erreicht in dem die Pixeln von jedem Trainingsbild vor dem Training in Bins klassifiziert wurden und daraus nur die am meisten vorkommenden 32 Bins ausgewählt wurden. Pixeln die nicht in den gewählten 32 Bins klassifiziert werden konnten, wurden in das nächstliegende Bin zugeordnet.

Der Methode mit einem MSE Loss ermöglicht eine um ein Vielfaches größere Auswahl an Farben für die Vorhersage. Bei dieser Methode treten die im Kapitel 2.4 erwähnten Schwierigkeiten, wobei in dem Fall von diesem Datensatz, diese Schwierigkeiten kaum zu erkennen waren. Da die Klassifikationsmethode leicht bessere Ergebnissen liefert hat und der Fokus der Arbeit auf Klassifikationsmethoden gesetzt war, wurden alle Experimenten des Landscape Datensatzes mit der Klassifikationsmethode durchgeführt.

Der Verlauf von dem Training und Validation Loss deutete bei diesem Datensatz zu overfitting, was bei der Größe des Datensatzes nicht auszuschließen war. Wie bei 5.2 beschrieben wurden das U-net und die Hyperparameter angepasst um dieses zu verhindern.

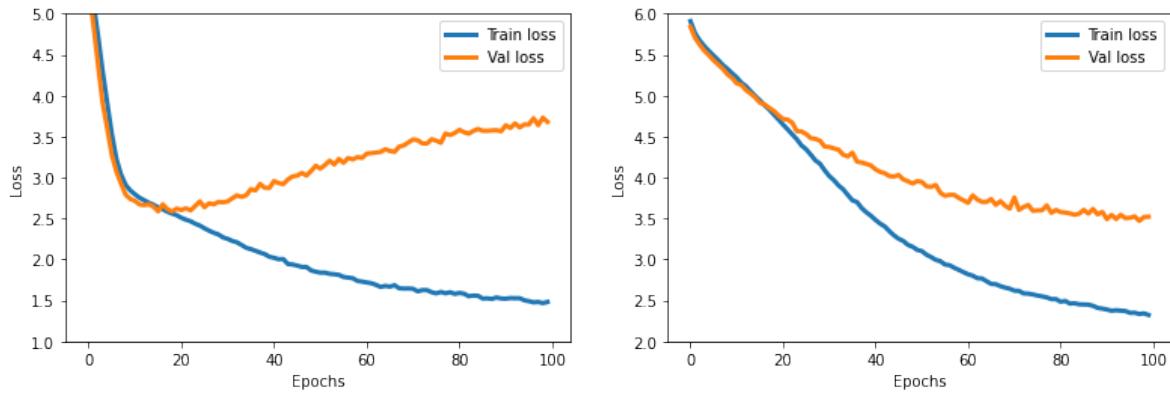


Abbildung 6.2: Overfitting auf dem CIFAR-100 Subset. **Links:** 100 Epochen mit Adam, ReLU und eine Lernrate von 0.001. **Rechts:** 100 Epochen mit Adam, ReLU und eine Lernrate von 0.0001.

Eine Anpassung der Lernrate führte nur zu einem langsameres Training. Eine Reduktion der lernbare Parameter von 135684 auf 35748 zeigte eine deutliche Verbesserung der Performance des Models und reduzierte das Overfitting.

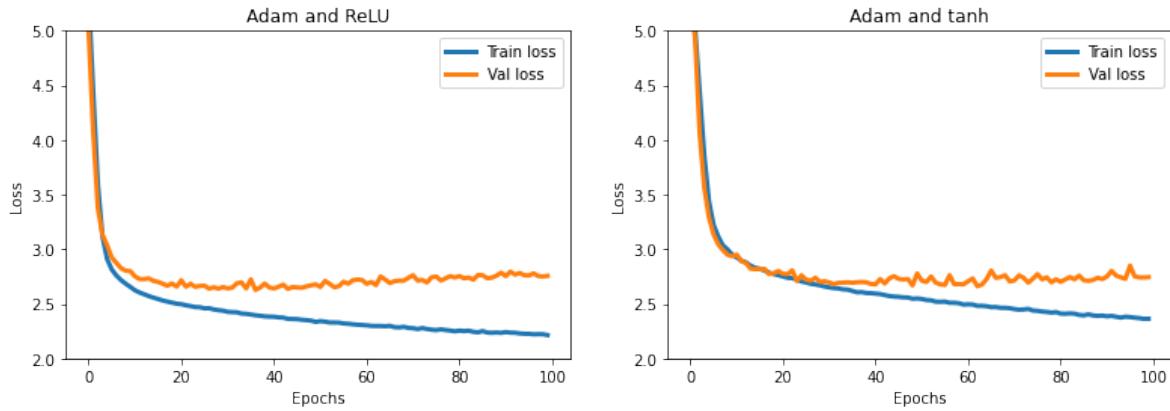


Abbildung 6.3: Loss Verlauf mit einer reduzierte Anzahl an Parameter und verschiedene Aktivierungsfunktionen. **Links:** 100 Epochen mit Adam, ReLU und eine Lernrate von 0.001. **Rechts:** 100 Epochen mit Adam, Tanh und eine Lernrate von 0.001.

Der Grund für das Overfitting ist in diesem Fall zu der Große des Subsets zurückzuführen. Um das zu prüfen wurde das Model auf das komplette CIFAR-100 Datensatz für 150 Epochen trainiert, was einen guten Loss Verlauf zeigte. Auf der anderen Seite, hat das Model nichts relevantes gelernt und konnte kein Bild richtig einfärben, was bei der Anzahl der Klassen und die Anzahl der Epochen normal ist.

6.4 Evaluation des Landscape Datensatzes

Die Ergebnisse dieses Model zeigen dass die ausgewählte Methode, mit wenige Bildexemplare und Epochen, sehr gute Ergebnisse erreichen kann. Die Anzahl der Bins für diesen Datensatz wurde durch die vorgeführten Experimenten auf 324 gesetzt, da dieser Anzahl die beste Kombination aus Trainingszeit und Performance erwiesen hat.

Der Loss Verlauf der Experimenten deutete ebenfalls bei diesem Datensatz nach wenige Epochen auf Overfitting. Nach Zahlreichen Experimenten konnte das Overfitting durch Anpassung der Hyperparameter nur minimiert werden. Für die Auswertung der Ergebnissen wurde das Model mit den besten Validation Loss verwendet.

Bei der Evaluation der Ergebnissen ist zu erkennen dass nach den wenigen Epochen

das Model die wichtigsten Entitäten wie der Himmel, Wolken, Wasser, Grass und Erde richtig Einfärben kann. Es fällt auf dass bei einigen Bildern, die Vorhersage des Models realer aussieht als das Originale Bild wie das zweite Beispiel von 5.6. Im Vergleich zu das Model von [BRT18] sehen die vorhergesagten Farben von dieses Model sehr ähnlich. Das zeigt dass die Performance der Methode ohne die Optimierungstechniken die bei [BRT18] angewendet wurden vergleichbar ist. Die Auswirkung der Temperaturwert ist auf beiden Modellen ähnlich, den Modus der Verteilung zeigt einen rötlichen Ton bei den Ergebnissen und den Durchschnitt zeigt bei einigen Fällen gesättigte Bilder.

Da das Datensatz Große von [BRT18] fast identisch zu der Datensatz Große dieser Arbeit ist, konnte das Problem mit dem Overfitting auf die Qualität des Datensatzes zurückzuführen sein. Deren Loss Verlauf zeigt kein Overfitting und das verwendete U-Net ist ähnlich wie das U-Net der vorliegende Arbeit, was ein Overfitting wegen der angewendete Netzwerkarchitektur ausschließt.

Ein Vergleich mit den Ergebnissen von [ZIE16] wäre nur fair mit den Ergebnissen aus deren Klassifikationsmodel ohne Rebalancing. In diesem Fall sind die Ergebnissen dieses Models nicht weit entfernt von deren Ergebnissen. Es ist zu erkennen dass deren Ergebnissen ähnliche Merkmale mit den Ergebnissen dieser Arbeit teilen, wie z.B. die Ähnlichkeit der Vorhersagen zwischen Klassifikationsmethode und Regressionsmethode. Die Ergebnissen mit Class Rebalancing unterscheiden sich deutlicher von der Ergebnissen der Regressionsmethode. Da deren Datensatz über 1.5 Millionen Bilder beinhaltet, kann das Model mehr Objekte auf den Bildern einfärben was sich bei einigen Bilder z.B. mit Menschen bemerkbar macht.

Im allgemeinen sind die Ergebnissen dieses Model mit anderen Ergebnissen von Klassifikationsmethoden ohne Optimierungstechniken wie Class Rebalancing vergleichbar.

Kapitel 7

Fazit

7.1 Zusammenfassung

Das Ziel dieser Bachelorarbeit war es, die Methoden von Image Colorization anhand Convolutional Neural Networks zu untersuchen, insbesondere Klassifikationsmethoden. Durch die ausführliche Auseinandersetzung mit Klassifikationsmethoden und die Implementierung der gebrauchten Techniken wie Binning, konnte eine Methode basierend auf den letzten Stand der Technik implementiert werden. Dieser Methode wurde angewandt und mit verschiedenen Datensätzen getestet um die Ergebnisse zu untersuchen.

Die Ergebnissen dieser Arbeit haben gezeigt dass die Methoden funktionieren und sogar mit wenigen Bildern und Epochen gute Ergebnissen produzieren. Zahlreiche Experimente bestätigten dass Klassifikationsmethoden bessere Ergebnisse als Regressionsmethoden liefern. Diese Differenz ist deutlicher bei Methoden die Optimierungstechniken, wie Class Rebalancing, anwenden.

7.2 Kritischer Rückblick

Der Fokus dieser Arbeit ist auf der Untersuchung der Methoden gelegt. Bei der Erstellung, Implementierung und Durchführung der Methode wurde festgestellt dass das Problem von Image Colorization sehr komplex ist. Obwohl die erreichten Ergebnissen ausreichend für den Vergleich mit anderen Methoden sind, wurde festgestellt dass ohne Optimierungstechniken eine Verbesserung der Qualität der Bilder sehr schwer ist.

Die Auswahl eines balancierten Datensatzes ist ein wichtiger Faktor für die Qualität

der Ergebnissen und kann Overfitting verhindern. Die Größe des Datensatzes ist auch entscheidend bei dem Training eines nicht vor-trainiertes Model.

Die Zielsetzung wurde erreicht in dem die Klassifikationsmethode bestätigt wurde, obwohl die Qualität der Ergebnissen durch weiteres Training und Optimierung verbessert werden kann.

7.3 Ausblick

Die implementierte Methode dieser Arbeit hat viel Potential und kann durch Anpassung der Techniken und Anwendung von Optimierungstechniken verbessert werden. Eine Anwendung auf andere und größere Datensätze wird mit Sicherheit bessere Ergebnissen produzieren. Es wäre auch interessant, die Methode auf Videos anzuwenden.

Methoden von dem Bereich unüberwachtes Lernen werden heutzutage angewendet um das Image Colorization Problem zu lösen. Generative adversarial Networks (GANs) werden in der Praxis öfters angewendet als normale CNNs da dieser viel bessere Ergebnissen erzeugen.

Abbildungsverzeichnis

2.1	Fully-connected Neural Network mit 2 Layers (ein Hidden Layer mit 4 Neuronen und ein Output Layer mit 2 Neuronen) [Fei20a]	5
2.2	Sigmoid Aktivierungsfunktion [Fei20b]	7
2.3	Tanh Aktivierungsfunktion [Fei20b]	8
2.4	Rectified Linear Unit (ReLU) [Fei20b]	9
2.5	Leaky ReLU [ccs20]	9
2.6	Typische Struktur von einem Convolutional Neural Network [Com15]	10
2.7	Beispiel Forward pass von einem Convolutional Layer mit einem $7 \times 7 \times 3$ Input Volumen, zwei $3 \times 3 \times 3$ Filter, Padding 1 und Stride 2. [Fei20c]	11
2.8	Max pooling Operation mit 2×2 Filtern und Stride 2 [Fei20c]	12
2.9	Gradient descent visualisiert [Bha18]	14
2.10	Backpropagation Beispiel anhand einer 2D Neuron mit der Aktivierungsfunktion Sigmoid [Fei20d]	15
2.11	Die Komplette Transposed Convolution Operation [Zha20]	16
3.1	Originales Bild in RGB oben links, den Belichtungskanal "L" oben rechts, unten links den Farbkanal "a" und unten rechts den Farbkanal "b".	20
3.2	Grid mit 36 bins. Die x-Achse bildet die Werte von dem Farbkanal "a" und die y-Achse die Werte von den Farbkanal "b" ab.	21
3.3	U-net Architektur (Beispiel für 32×32 Pixels in der niedrigste Auflösung). Jeder blaue Box entspricht ein multi-Kanal Feature Map. Die Tiefe der Feature Maps ist gekennzeichnet durch die Zahl über die Box. Die Breite und Höhe ist durch die Zahl unten links erkennbar. Die weiße Boxen repräsentieren die kopierte Feature Maps. Die Pfeile bestimmen die verschiedene Operationen. [RFB15]	24
3.4	Beispiel von Trainingsbildern mit einer der möglichen Farbe pro Klasse	25
4.1	ConvBlock	31
4.2	U-Net Architektur für 128×128 Input Bilder	32

5.1	Beispiele von sehr gute Ergebnisse aus dem Spiel-Datensatz	33
5.2	Beispiele von generalisierte Ergebnisse	34
5.3	Beispiele von gute Ergebnisse aus dem Subset von CIFAR-100 mit 324 Bins. Die erste Spalte beinhaltet das Graustufenbild, die zweite Spalte beinhaltet das Originale Bild und die letzte Spalte stellt das generierte Bild dar. Das generierte Bild wurde mit eine Temperatur von 1 erzeugt, was bedeutet dass die rekonstruierte Farben den Durchschnitt aus jedem Bin repräsentieren. .	35
5.4	Einfluss von Anzahl der Bins auf die Ergebnisse. Das zweite Bild ist das originale, das dritte Bild wurde mit 36 Bins und ein Temperaturwert von 1 generiert und das vierte nur mit 324 Bins und ebenfalls mit ein Tempera- turwert von 1.	36
5.5	Vergleich von Klassifikation mit Binning gegenüber Regression. Das zweite Bild wurde mit 324 Bins und der Cross Entropy Loss generiert. Das dritte Bild wurde ohne Binning und mit einem MSE Loss generiert.	37
5.6	Ergebnisse mit 324 Bins. Die erste Spalte zeigt das Originale Bild, die zweite zeigt das generierte Bild mit einer Temperatur von 0, die dritte Spalte zeigt das generierte Bild mit einer Temperatur von 0.8 und die vierte Spalte zeigt das generierte Bild mit einer Temperatur von 1	38
5.7	Ergebnisse mit 36 und 324 Bins. Die erste Spalte zeigt das Graustufenbild, die zweite zeigt das originale Bild, die dritte Spalte zeigt das mit 36 Bins generierte Bild mit einer Temperatur von 1 und die vierte Spalte zeigt das mit 324 Bins generierte Bild mit einer Temperatur von 1	38
6.1	Training und Validation Loss Verlauf von dem Spiel-Datensatz	40
6.2	Overfitting auf dem CIFAR-100 Subset. Links: 100 Epochen mit Adam, ReLU und eine Lernrate von 0.001. Rechts: 100 Epochen mit Adam, ReLU und eine Lernrate von 0.0001.	41
6.3	Loss Verlauf mit eine reduzierte Anzahl an Parameter und verschiedene Aktivierungsfunktionen. Links: 100 Epochen mit Adam, ReLU und ei- ne Lernrate von 0.001. Rechts: 100 Epochen mit Adam, Tanh und eine Lernrate von 0.001.	42

Source Code Content

4.1	Binning eines normalisierten Lab Bildes	29
4.2	Leeres Dictionary Erzeugung für n_bins	29
4.3	Bin zu Farbe Umwandlung	30
4.4	Bin zu Farbe Berechnung mit einem Temperaturwert	30

Glossar

Bin Behälter. 17, 20

CIE Internationale Beleuchtungskommission. 17

CNN Convolutional Neural Network (Gefaltetes Neuronales Netzwerk). 9, 10, 22, 45, IV

Grid Raster. 20, 21, 28, I

Layer Schicht. 3, 10, 11, I

Loss Function Kostenfunktion. 12, 13, 15, 17

Stride Schrittweite einer Faltung bei einem CNN. 10, 11, I

Literaturverzeichnis

- [BRT18] Vincent Billaut, Matthieu de Rochemonteix und Marc Thibault. *ColorUNet: A convolutional classification approach to colorization*. 2018. arXiv: 1811.03120 [cs.CV]. (Besucht am 01.08.2020).
- [DHS11] John Duchi, Elad Hazan und Yoram Singer. „Adaptive subgradient methods for online learning and stochastic optimization“. In: *Journal of Machine Learning Research* 12.Jul (2011), S. 2121–2159.
- [GBC16] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [KB14] Diederik P. Kingma und Jimmy Ba. *Adam: A Method for Stochastic Optimization*. 2014. arXiv: 1412.6980 [cs.LG].
- [LLW04] Anat Levin, Dani Lischinski und Yair Weiss. „Colorization Using Optimization“. In: *ACM Trans. Graph.* 23.3 (Aug. 2004), S. 689–694. ISSN: 0730-0301. DOI: 10.1145/1015706.1015780. URL: <https://doi.org/10.1145/1015706.1015780>.
- [NH10] Vinod Nair und Geoffrey E. Hinton. „Rectified Linear Units Improve Restricted Boltzmann Machines“. In: *Proceedings of the 27th International Conference on International Conference on Machine Learning*. ICML’10. Haifa, Israel: Omnipress, 2010, S. 807–814. ISBN: 9781605589077. (Besucht am 27.07.2020).
- [Özb19] Gökhan Özbulak. *Image Colorization By Capsule Networks*. 2019. arXiv: 1908.08307 [eess.IV].
- [RFB15] Olaf Ronneberger, Philipp Fischer und Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. arXiv: 1505.04597 [cs.CV].
- [Zha20] Aston Zhang u. a. *Dive into Deep Learning*. <https://d2l.ai>. 2020.
- [ZIE16] Richard Zhang, Phillip Isola und Alexei A. Efros. *Colorful Image Colorization*. 2016. arXiv: 1603.08511 [cs.CV]. (Besucht am 01.08.2020).

Onlinereferenzen

- [15] *Backpropagation*. 2015. URL: <http://www.inztitut.de/blog/glossar/backpropagation/> (besucht am 01.08.2020).
- [Bec19] Roland Becker. *Convolutional Neural Networks – Aufbau, Funktion und Anwendungsbiete*. 2019. URL: <https://jaai.de/convolutional-neural-networks-cnn-aufbau-funktion-und-anwendungsbiete-1691/> (besucht am 01.08.2020).
- [Dip19] Nico Litzel Dipl.-Ing. (FH) Stefan Luber. *Was ist ein Convolutional Neural Network?* 2019. URL: <https://www.bigdata-insider.de/was-ist-ein-convolutional-neural-network-a-801246/> (besucht am 01.08.2020).
- [Fei17a] Serena Yeung Fei-Fei Li Justin Johnson. *Neural Networks 1*. 2017. URL: <https://cs231n.github.io/neural-networks-1/> (besucht am 12.07.2020).
- [Fei17b] Serena Yeung Fei-Fei Li Justin Johnson. *Optimization 2*. 2017. URL: <https://cs231n.github.io/optimization-2/> (besucht am 01.08.2020).
- [Moe18] Julian Moeser. *Funktionsweise und Aufbau künstlicher neuronaler Netze*. 2018. URL: <https://jaai.de/kuenstliche-neuronale-netze-aufbau-funktion-291/> (besucht am 10.07.2020).
- [Ngu20] Hoang Tu Nguyen. *Einführung in die Welt der Autoencoder*. 2020. URL: [%5Curl%7Bhttps://data-science-blog.com/blog/2020/04/01/einfuehrung-in-die-welt-der-autoencoder/%7D](https://data-science-blog.com/blog/2020/04/01/einfuehrung-in-die-welt-der-autoencoder/) (besucht am 01.08.2020).

Bildreferenzen

- [Bha18] Saugat Bhattacharai. *What is gradient descent in machine learning?* 2018. URL: <https://saugatbhattacharai.com.np/what-is-gradient-descent-in-machine-learning/> (besucht am 01.08.2020).
- [ccs20] ccs96307. 2020. URL: <https://clay-atlas.com/us/blog/2020/02/03/machine-learning-english-note-relu-function/> (besucht am 31.07.2020).
- [Com15] Wikimedia Commons. *Typical CNN architecture.* 2015. URL: https://upload.wikimedia.org/wikipedia/commons/6/63/Typical_cnn.png (besucht am 03.04.2018).
- [Fei20a] Serena Yeung Fei-Fei Li Justin Johnson. 2020. URL: <https://cs231n.github.io/neural-networks-1/> (besucht am 10.07.2020).
- [Fei20b] Serena Yeung Fei-Fei Li Justin Johnson. 2020. URL: <https://cs231n.github.io/neural-networks-1/> (besucht am 12.07.2020).
- [Fei20c] Serena Yeung Fei-Fei Li Justin Johnson. 2020. URL: <https://cs231n.github.io/convolutional-networks/> (besucht am 01.08.2020).
- [Fei20d] Serena Yeung Fei-Fei Li Justin Johnson. 2020. URL: <https://cs231n.github.io/optimization-2/> (besucht am 01.08.2020).

Anhang A

TODO

Eigenständigkeitserklärung

Hiermit versichere ich, dass ich die vorliegende Bachelorarbeit selbstständig und nur unter Verwendung der angegebenen Quellen und Hilfsmittel verfasst habe. Die Arbeit wurde bisher in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt.

Berlin, den XX.XX.2018

Adrian Saiz Ferri